Scuola di Scienze Matematiche, Fisiche e Naturali
Corso di Laurea Magistrale in Informatica
Tesi di Laurea

RICONOSCIMENTO DI AZIONI UMANE USANDO TECNICHE DI APPRENDIMENTO PROFONDO PER LA STIMA DELLA POSA

Andrea Moscatelli

Relatore: *Marco Bertini*

Anno accademico 2018-2019

UNIVERSITÀ DEGLI STUDI FIRENZE

Outline

- Concetti chiave
- La stima della posa
- Dataset NTU-RGB+D
- Metodo proposto e risultati
- Conclusioni e sviluppi futuri

Concetti chiave

Riconoscimento di **azioni umane** = stima della **posa** + **apprendimento profondo**

Concetti chiave

Riconoscimento di **azioni umane** = stima della **posa** + **apprendimento profondo**

Saper riconoscere potenzialmente qualsiasi azione umana, sia individuale che di gruppo, ripresa in video:

- *bere*
- *mangiare*
- *scrivere*
- *telefonare*
- *mettersi le mani in tasca*
- *indicare qualcuno*
- *darsi la mano*
- *picchiarsi*
- *abbracciarsi*
- …

Concetti chiave

Riconoscimento di **azioni umane** = stima della **posa** + **apprendimento profondo**

Definizione di **posa** (in computer vision):

"Combinazione di posizione e orientamento di un oggetto"

La posa umana (o di oggetti) può essere di due tipi:

Volumetrica

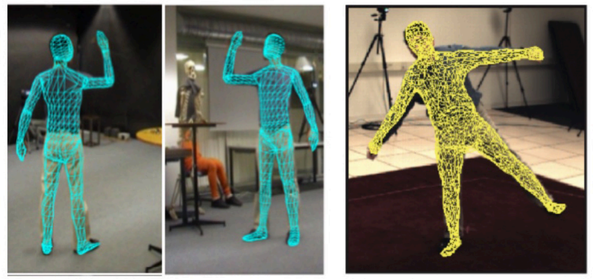

Composta da molti punti e orientata alla tridimensionalità del soggetto

Scheletrica

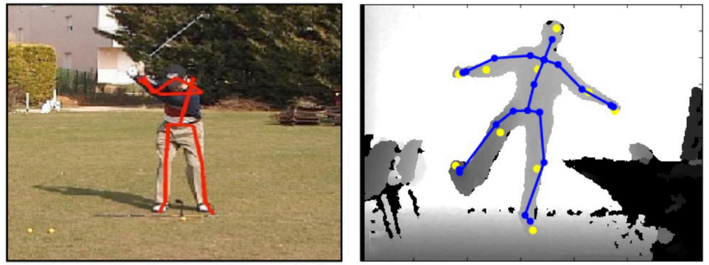

Composta da pochi punti e orientata ad una schematizzazione efficace del soggetto

Concetti chiave

Riconoscimento di **azioni umane** = stima della **posa** + **apprendimento profondo**

Definizione di **posa** (in computer vision):

"Combinazione di posizione e orientamento di un oggetto"

La posa umana (o di oggetti) può essere di due tipi:

Volumetrica

Composta da molti punti e orientata alla tridimensionalità del soggetto

Scheletrica

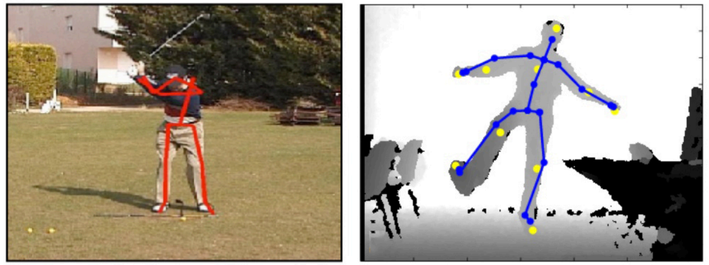

Composta da pochi punti e orientata ad una schematizzazione efficace del soggetto

Concetti chiave

Riconoscimento di **azioni umane** = stima della **posa** + **apprendimento profondo**

L'**apprendimento profondo** (o **Deep learning**) è quella branca dell'*apprendimento automatico* (o *Machine learning*) basata su diversi **livelli** di rappresentazione dove i valori di alto livello sono definiti sulla base di quelli di basso.

Lo strumento utilizzato è la **rete neurale artificiale**, organizzata in diversi strati ognuno dei quali calcola i valori per quello successivo affinché l'informazione venga elaborata in maniera sempre più completa.

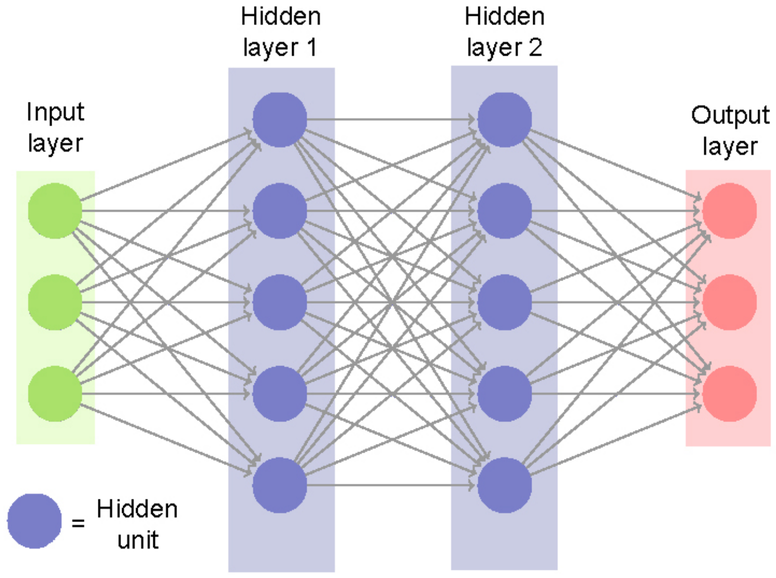

Concetti chiave

Riconoscimento di **azioni umane** = stima della **posa** + **apprendimento profondo**

L'**apprendimento profondo** (o **Deep learning**) è quella branca dell'*apprendimento automatico* (o *Machine learning*) basata su diversi **livelli** di rappresentazione dove i valori di alto livello sono definiti sulla base di quelli di basso.

In questo lavoro di tesi la rete neurale usata è una combinazione di livelli **Long Short-Term Memory** (**LSTM**), della famiglia delle *reti neurali ricorrenti,* particolarmente adatte alla classificazione di sequenze temporali

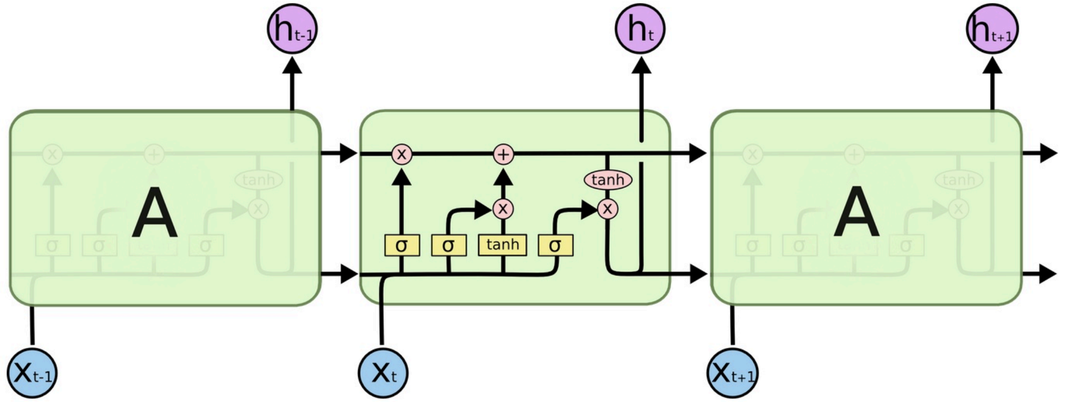

La stima della posa

Detectron2

modello : *Mask R-CNN*
backbone : *ResNeXt+FPN*
pre-allenato su : *ImageNet*

- Accuratezza allo stato dell'arte

PoseNet

modello : *PersonLab*
backbone : *MobileNetV1*
pre-allenato su : *COCO-2016*

- *Leggerezza modello*
- *Rapidità d'inferenza*

La stima della posa

Detectron2

modello : *Mask R-CNN*
backbone : *ResNeXt+FPN*
pre-allenato su : *ImageNet*

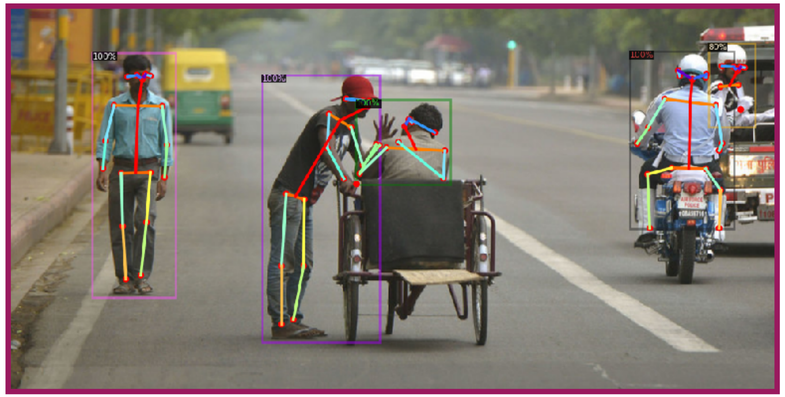

PoseNet

modello : *PersonLab*
backbone : *MobileNetV1*
pre-allenato su : *COCO-2016*

La stima della posa

Detectron2

modello : *Mask R-CNN*
backbone : *ResNeXt+FPN*
pre-allenato su : *ImageNet*

PoseNet

modello : *PersonLab*
backbone : *MobileNetV1*
pre-allenato su : *COCO-2016*

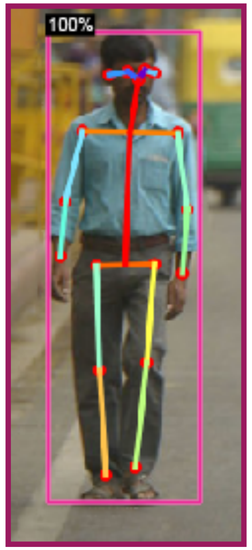

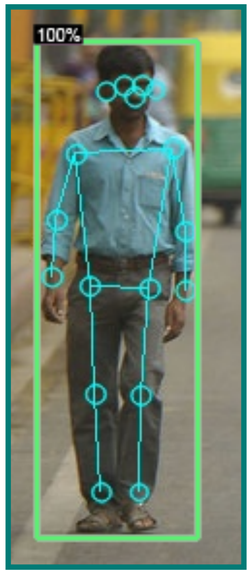

- **17 punti** per persona
- **score [0,1]** per persona

Dataset utilizzato

UNIVERSITÀ DEGLI STUDI FIRENZE

NTU-RGB+D

- anno 2016
- **56880** video
  - RGB
  - ~~frame di profondità~~
  - ~~pose~~
  - ~~frame ad infrarossi~~
- **60** azioni
  - 50 individuali
  - 10 di coppia
- **3** angolazioni di ripresa
- **2** ripetizioni
- **40** attori (10-35 anni)

Dataset utilizzato

NTU-RGB+D

- anno 2016
- **56880** video
  - RGB
  - ~~frame di profondità~~
  - ~~pose~~
  - ~~frame ad infrarossi~~
- **60** azioni
  - 50 individuali
  - 10 di coppia
- **3** angolazioni di ripresa
- **2** ripetizioni
- **40** attori (10-35 anni)

Ripetizione **1**

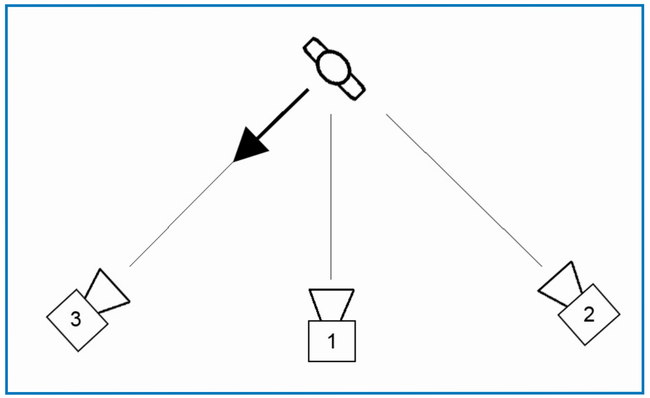

Ripetizione **2**

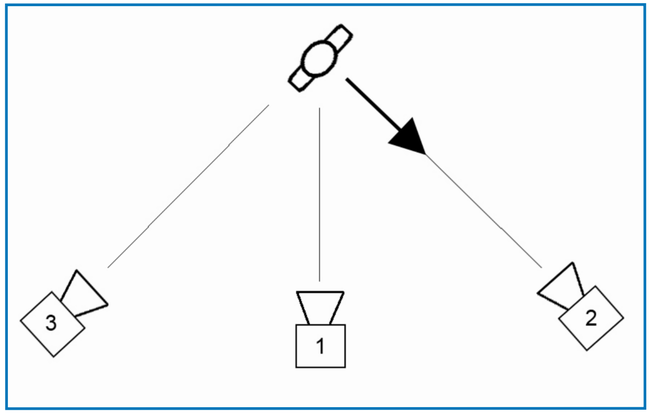

Dataset utilizzato

UNIVERSITÀ DEGLI STUDI FIRENZE

NTU-RGB+D

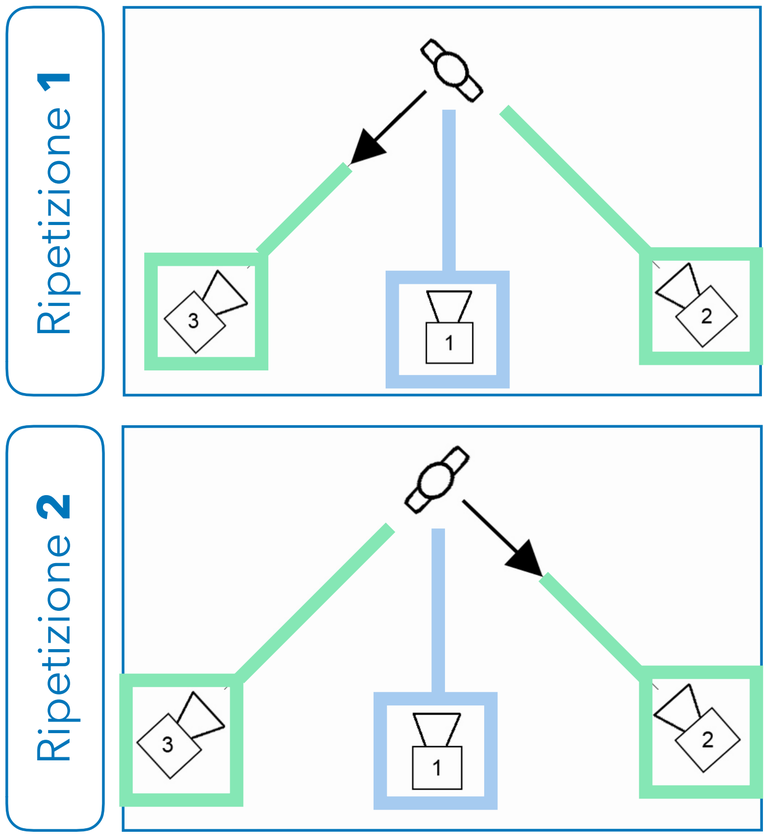

Cross View

Training

id **camera**: *2,3*
video: *37920*

contiene tutte le prospettive **frontali** e a **90°**

Test

id **camera**: *1*
video: *18960*

contiene tutte le prospettive a **45°**

Dataset utilizzato

NTU-RGB+D

Cross Subject

Training

id **attori**: *1, 2, 4, 5, 8, 9, 13, 14, 15, 16, 17, 18, 19, 25, 27, 28, 31, 34, 35, 38*

video: *40320*

Test

id **attori**: *tutti gli altri*

video: *16560*

Cross View

Training

id **camera**: *2,3*

video: *37920*

Test

id **camera**: *1*

video: *18960*

Metodo proposto - **Preprocessing**

UNIVERSITÀ DEGLI STUDI FIRENZE

Assegnazione coerente delle pose

Frame 1	Frame 12	Frame 43	Frame 62
		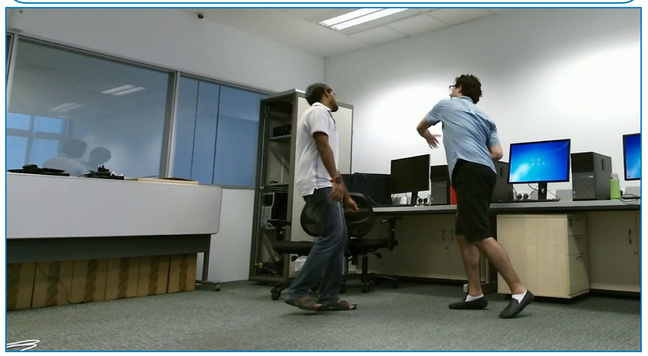	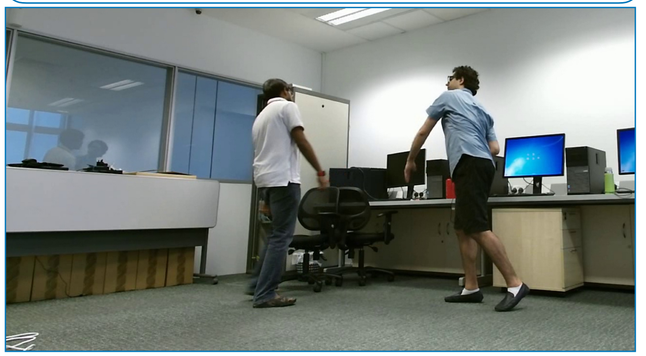
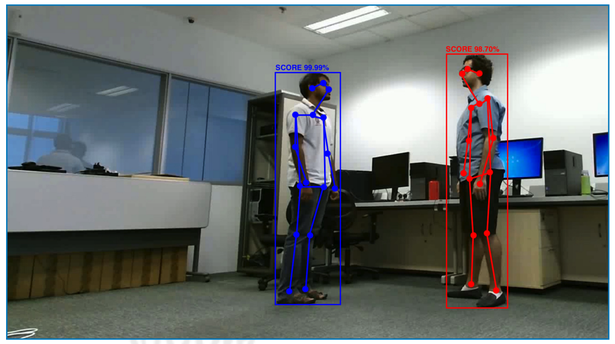	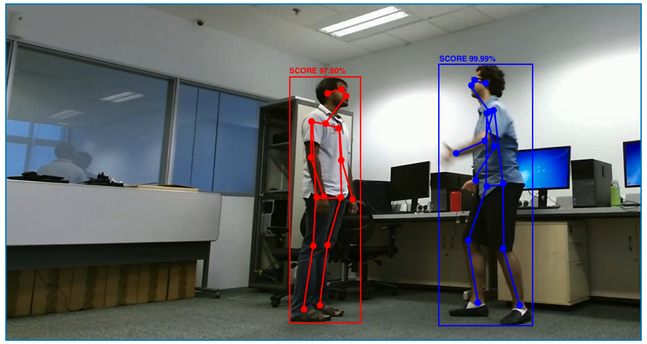	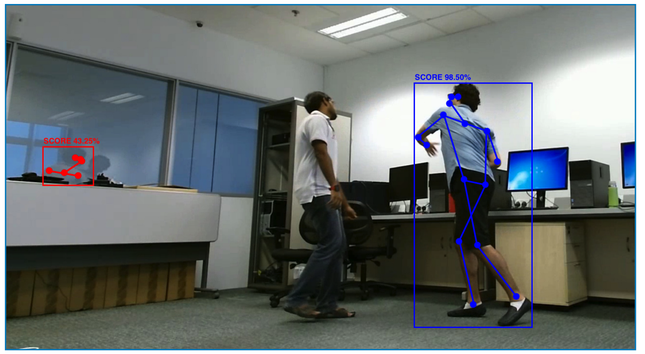	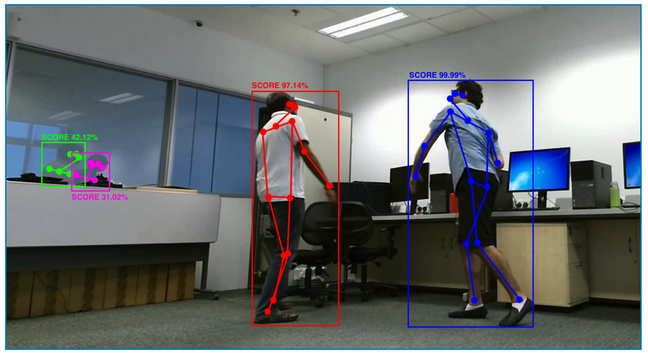

Ordine delle pose restituite dall'algoritmo:

Metodo proposto - **Preprocessing**

UNIVERSITÀ DEGLI STUDI FIRENZE

Assegnazione coerente delle pose

K = tipi di punti chiave (giunti)

Posa $\mathcal{P}_i = \{p_{i,k}\}_{k=1}^{K}$

$p_{i,k} = (x_{i,k}, y_{i,k})$

$I(p) =$ 1 se p è definito, 0 altrimenti

Distanza $\mathcal{D}_{ij} = \sum_{k=1}^{K} I(p_{i,k}) \cdot I(p_{j,k}) \cdot \mathrm{eucl}(p_{i,k}, p_{j,k})$

Regole di selezione

1) Le sequenze di pose vengono create seguendo le **distanze minime** fra pose di frame consecutivi

2) Per ogni video, solo le **2** sequenze di pose col **maggior score medio** sono state selezionate

Metodo proposto - **Preprocessing**

UNIVERSITÀ DEGLI STUDI FIRENZE

Rimozione degli zeri

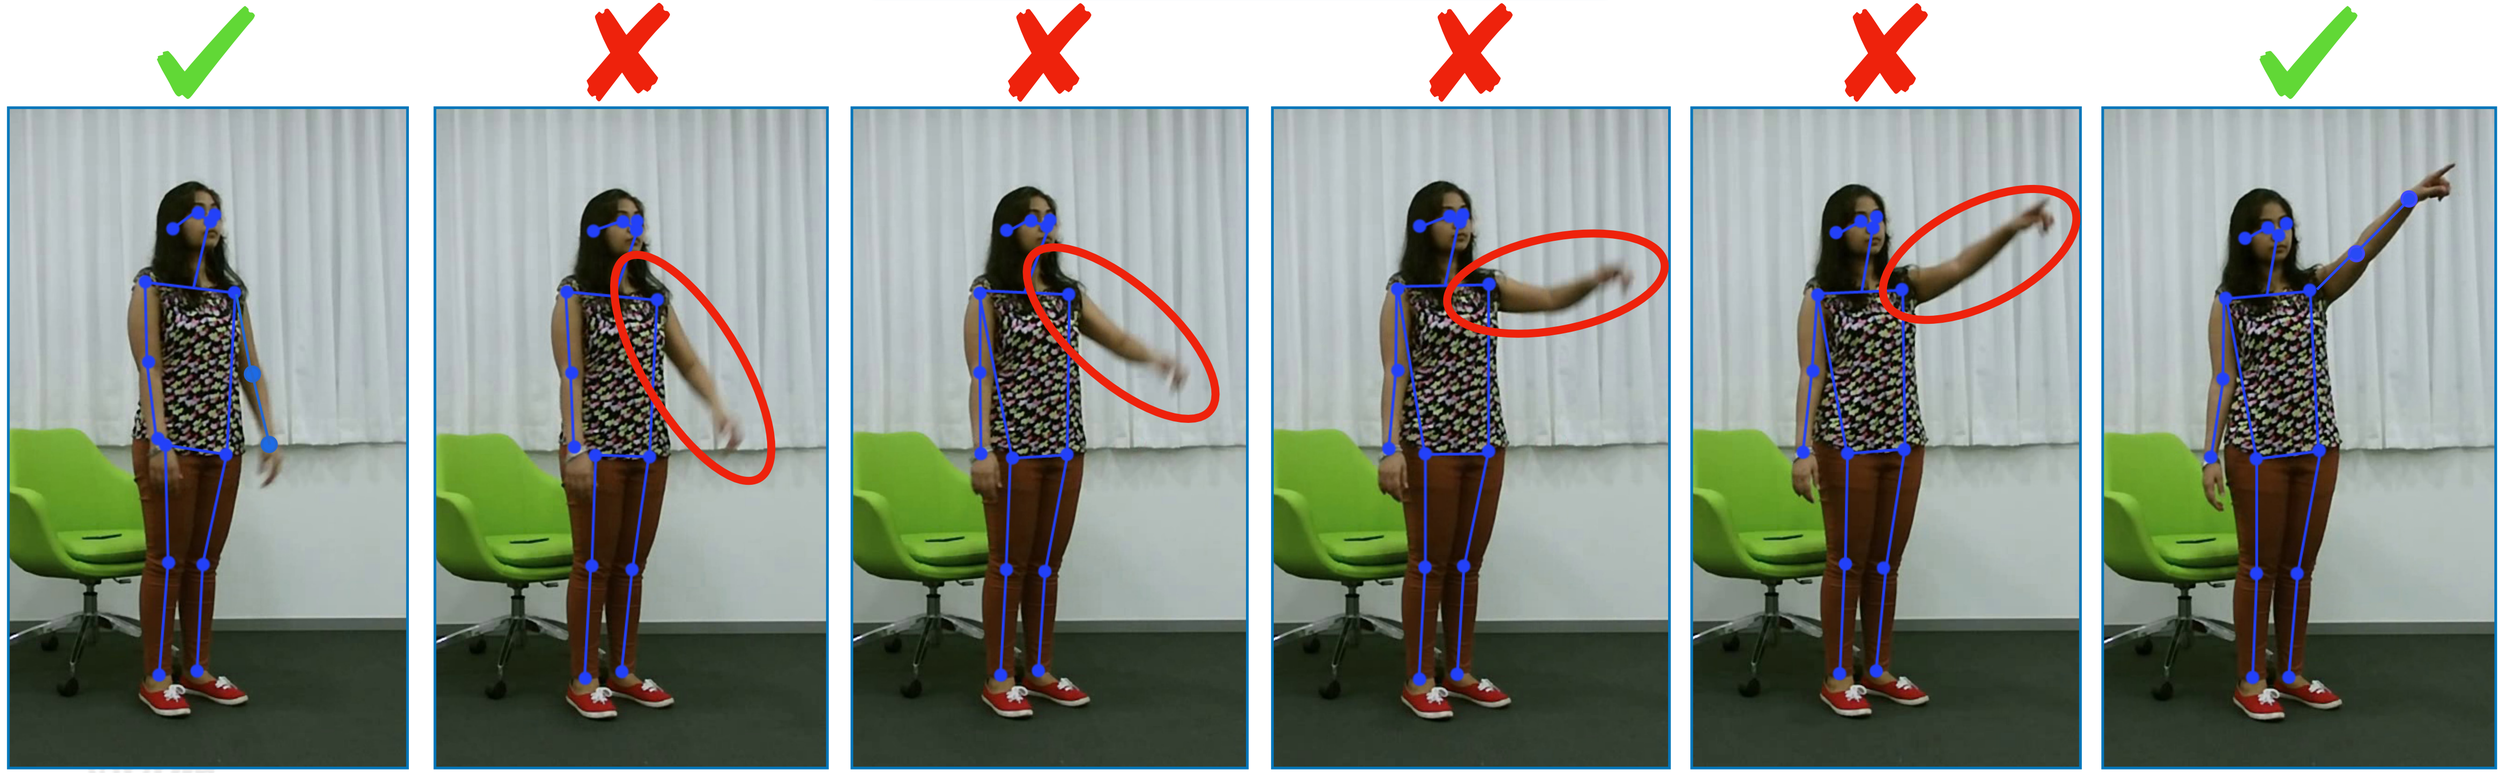

Frame 1 **Frame 2** **Frame 3** **Frame 4** **Frame 5** **Frame 6**

Tempo

Metodo proposto - **Preprocessing**

UNIVERSITÀ DEGLI STUDI FIRENZE

Rimozione degli zeri

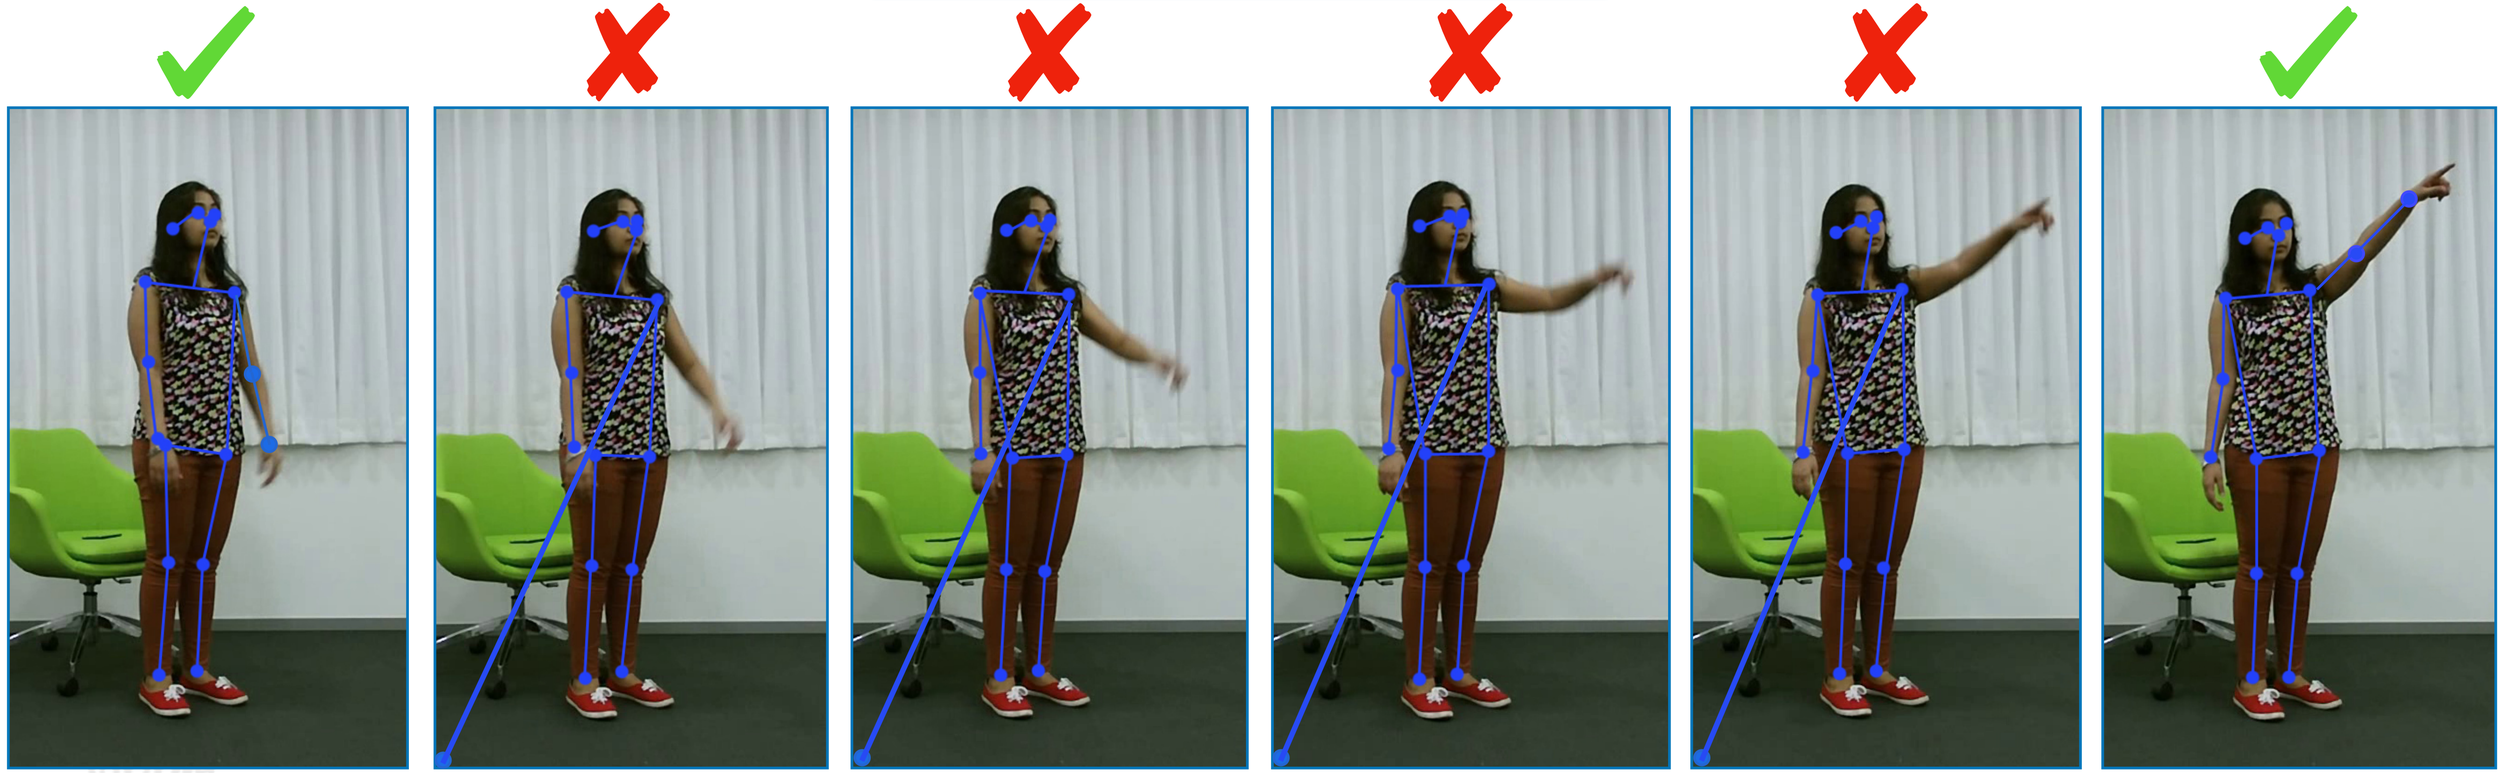

Frame 1 **Frame 2** **Frame 3** **Frame 4** **Frame 5** **Frame 6**

Tempo

Metodo proposto - **Preprocessing**

UNIVERSITÀ DEGLI STUDI FIRENZE

Rimozione degli zeri

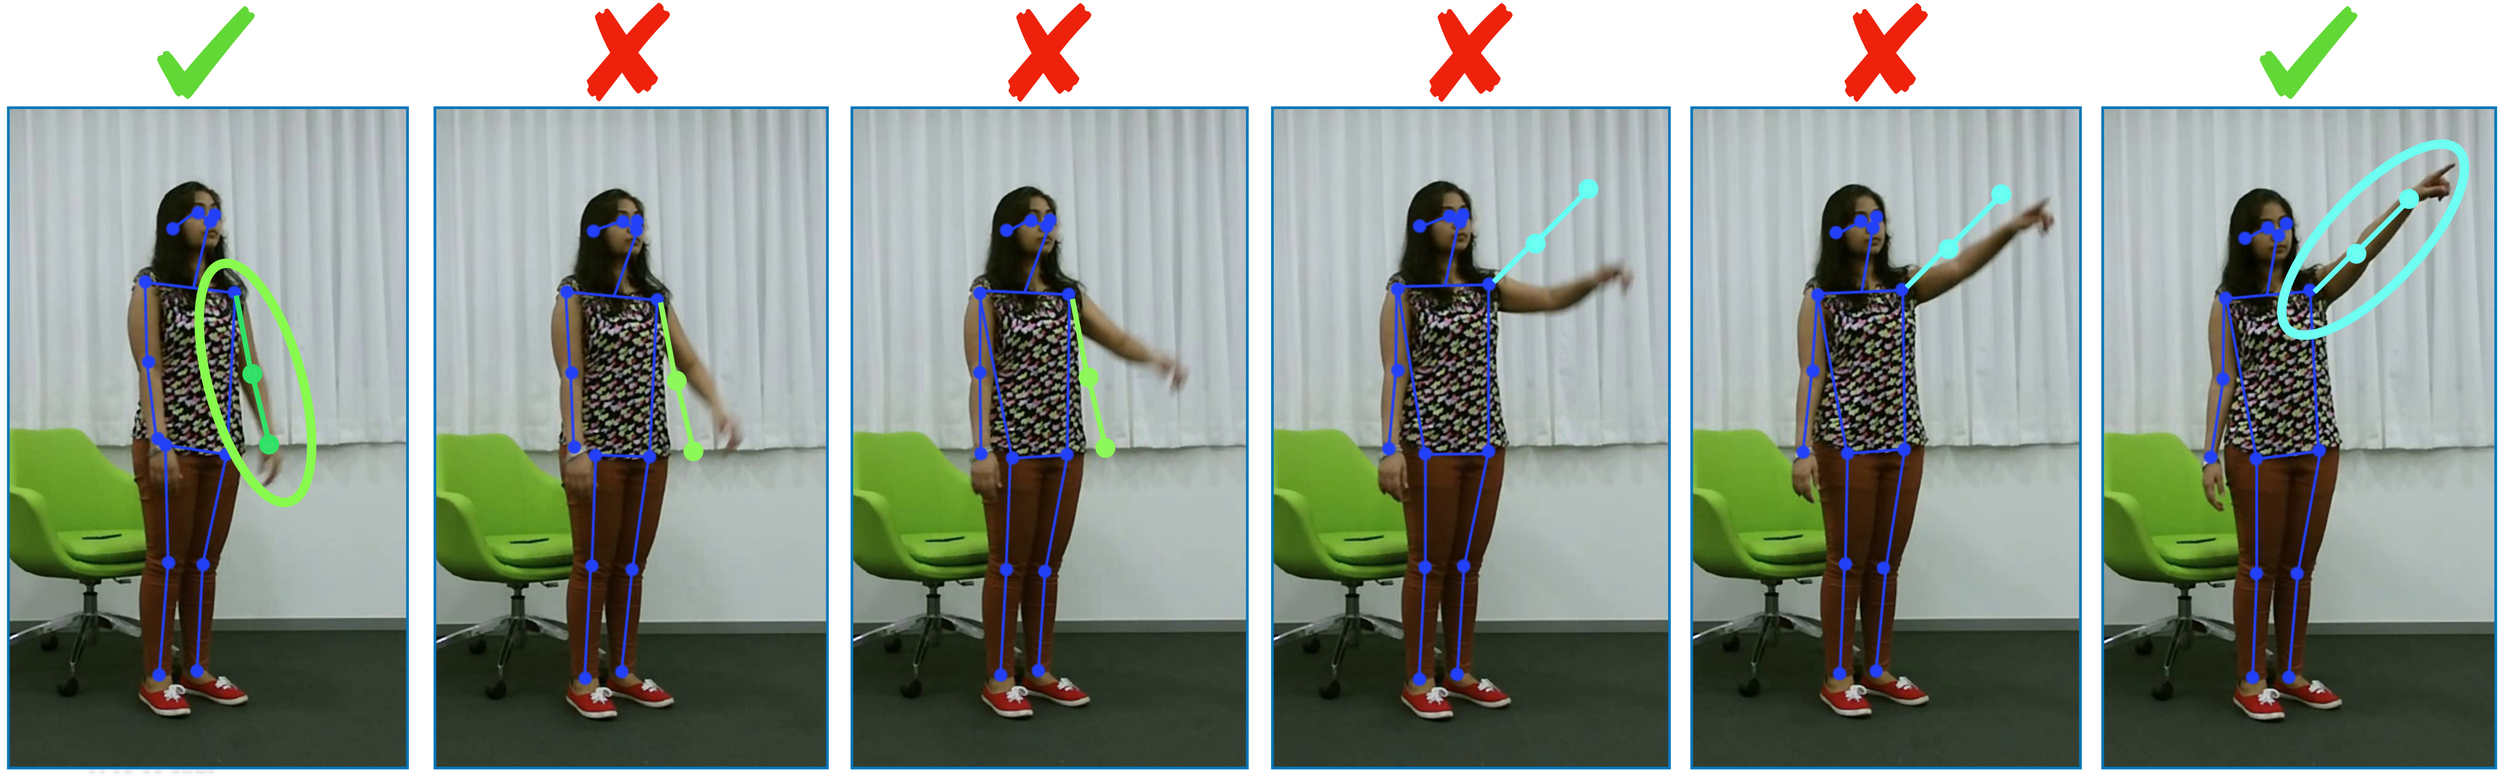

Frame 1 **Frame 2** **Frame 3** **Frame 4** **Frame 5** **Frame 6**

Tempo

Metodo proposto - **Tecniche di rielaborazione**

UNIVERSITÀ DEGLI STUDI FIRENZE

Semplice

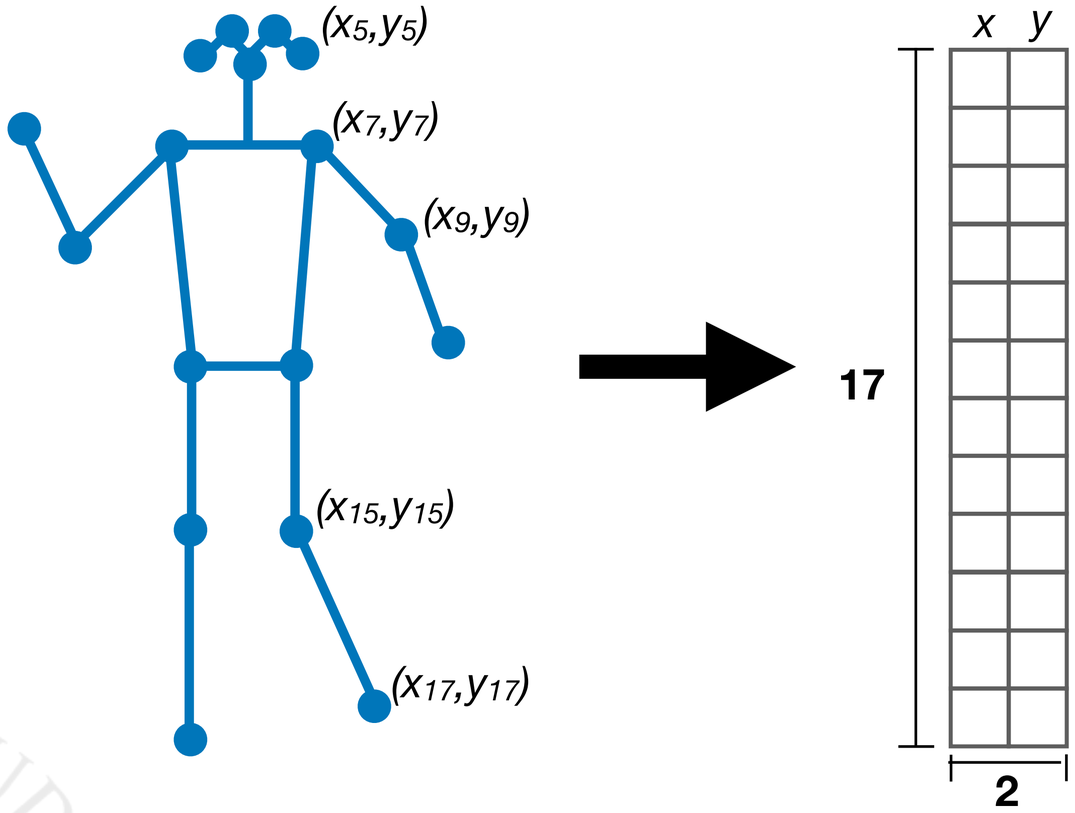

Metodo proposto - **Tecniche di rielaborazione**

UNIVERSITÀ DEGLI STUDI FIRENZE

Semplice

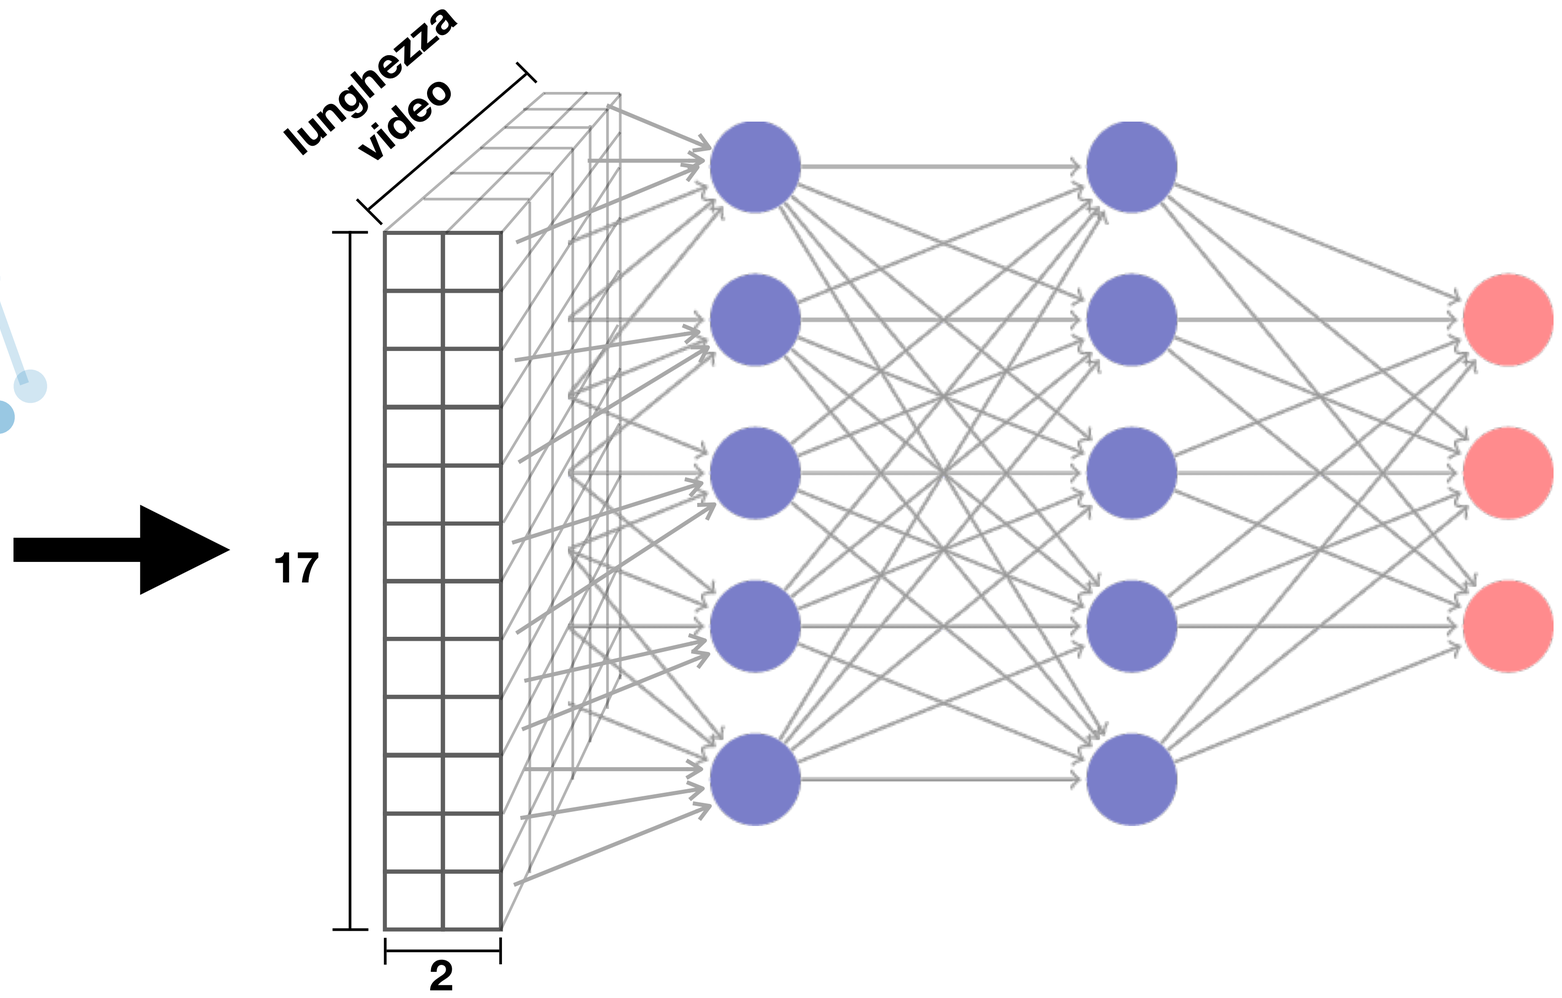

Metodo proposto - **Tecniche di rielaborazione**

UNIVERSITÀ DEGLI STUDI FIRENZE

Semplice

Baricentro

Frame

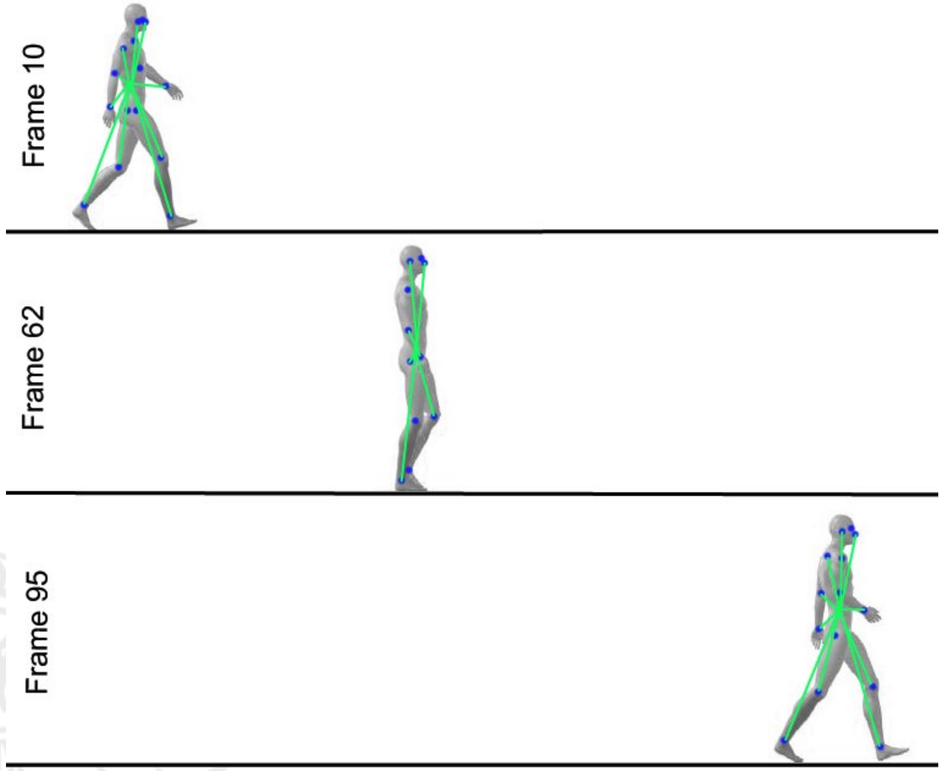

Baricentro posa: $\overline{\mathcal{P}_f} = \frac{\sum_{j=1}^{K} p_{jf}}{K}$

Trasformazione posa: $\mathcal{T}_f = \{\mathbf{t}_{1f}, ..., \mathbf{t}_{Kf}\}$

Personale

$$\mathbf{t}_{if} = \mathbf{p}_{if} - \overline{\mathcal{P}_f}$$

Globale

$$\overline{\mathcal{G}_f} = \frac{\overline{\mathcal{P}_{1,f}} + \overline{\mathcal{P}_{2,f}}}{2}$$

$$\mathbf{t}_{if} = \mathbf{p}_{if} - \overline{\mathcal{G}_f}$$

Metodo proposto - **Tecniche di rielaborazione**

UNIVERSITÀ DEGLI STUDI FIRENZE

Semplice | **Baricentro**

Frame | Video

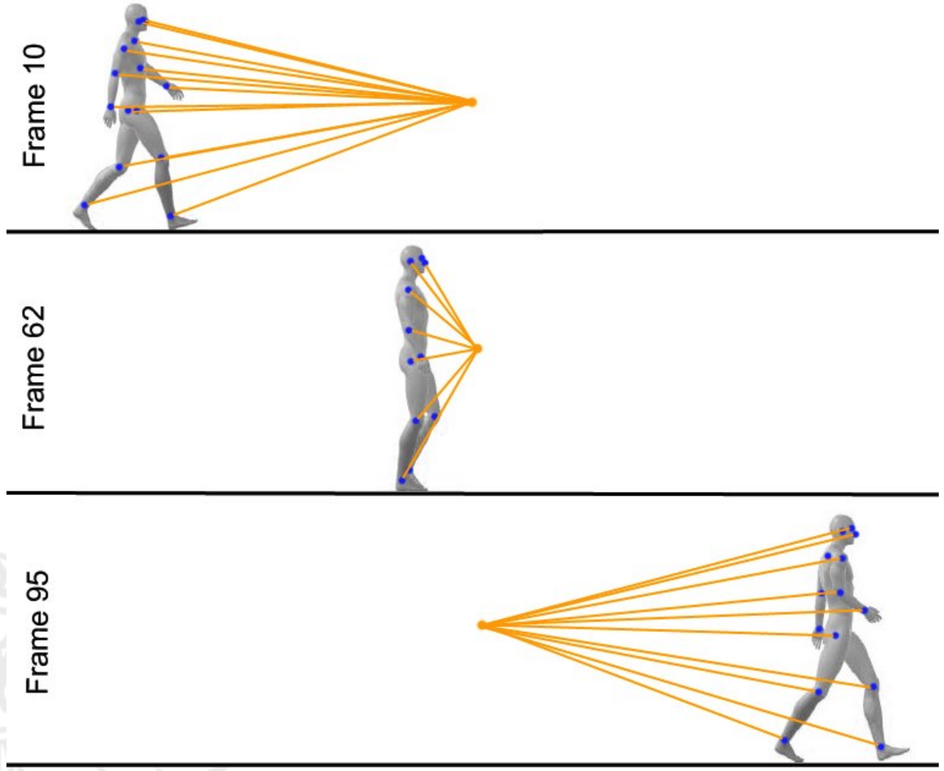

Baricentro video: $\overline{\mathcal{V}} = \frac{\sum_{f=1}^{L} \overline{\mathcal{P}_f}}{L}$

Trasformazione posa: $\mathcal{T}_f = \{\mathbf{t}_{1f}, ..., \mathbf{t}_{Kf}\}$

Personale

$$\mathbf{t}_{if} = \mathbf{p}_{if} - \overline{\mathcal{V}}$$

Globale

$$\overline{\mathcal{V}_G} = \frac{\sum_{f=1}^{L} \overline{\mathcal{G}_f}}{L}$$

$$\mathbf{t}_{if} = \mathbf{p}_{if} - \overline{\mathcal{V}_G}$$

Metodo proposto - **Tecniche di rielaborazione**

UNIVERSITÀ DEGLI STUDI FIRENZE

Semplice | **Baricentro**

Frame | Video | Video multiplo

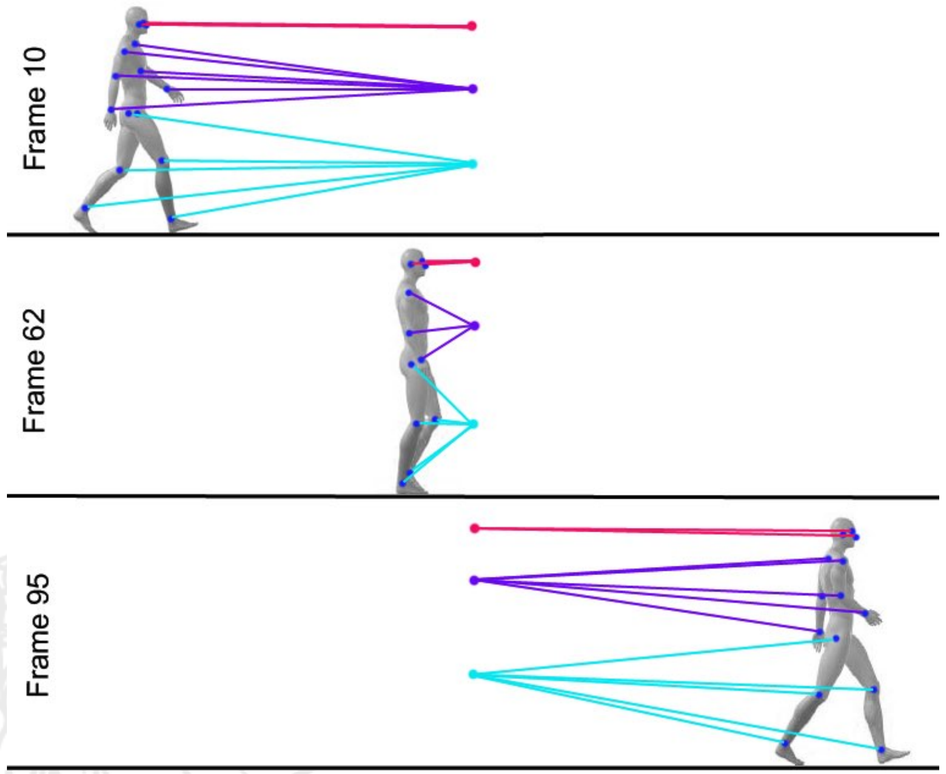

B sottogruppi: $K = \{\mathcal{K}_1, ..., \mathcal{K}_B\}, \quad \bigcup_{b=1}^{B} \mathcal{K}_b = K$

$$\mathcal{K}_i \bigcap \mathcal{K}_j = \emptyset, \quad \forall\, \mathcal{K}_i, \mathcal{K}_j \in K$$

Baricentro video: $\overline{\mathcal{B}_b} = \dfrac{\bigcup_{i \in \mathcal{B}_b} \sum_{f=1}^{L} \mathbf{p}_{if}}{L}$

Trasformazione posa: $\mathcal{T}_f = \{\mathbf{t}_{1f}, ..., \mathbf{t}_{Kf}\}$

Personale

$$\mathbf{t}_{if} = \mathbf{p}_{if} - \overline{\mathcal{B}_b}$$

Assoluta

$$\mathbf{t}_{if} = |\mathbf{p}_{if} - \overline{\mathcal{B}_b}|$$

Globale

$$\overline{\mathcal{G}_b} = \frac{\bigcup_{i \in \mathcal{B}_b} \sum_{f=1}^{L} \mathbf{mean}(\mathbf{p}_{1if}, \mathbf{p}_{2if})}{L}$$

$$\mathbf{t}_{if} = \mathbf{p}_{if} - \overline{\mathcal{G}_b}$$

Metodo proposto - **Tecniche di rielaborazione**

UNIVERSITÀ DEGLI STUDI FIRENZE

Semplice | **Baricentro**

Frame | Video | Video multiplo

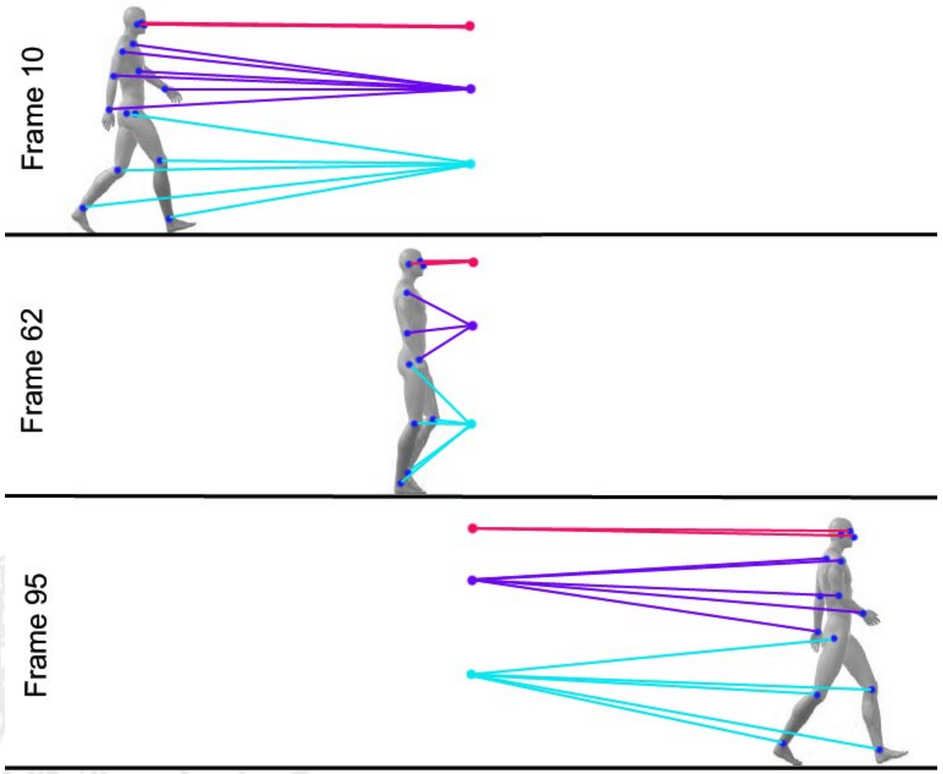

B sottogruppi: $K = \{\mathcal{K}_1, ..., \mathcal{K}_B\}, \quad \bigcup_{b=1}^{B} \mathcal{K}_b = K$

$$\mathcal{K}_i \bigcap \mathcal{K}_j = \emptyset, \quad \forall\, \mathcal{K}_i, \mathcal{K}_j \in K$$

- **B** = **3**: Testa - Busto - Gambe

- **B** = **5**: Come suggerita dagli autori di NTU-RGB+D

- **B** = **17**: Un baricentro per ogni giunto

Metodo proposto - **Tecniche di rielaborazione**

UNIVERSITÀ DEGLI STUDI FIRENZE

Semplice | Baricentro | **Next frame**

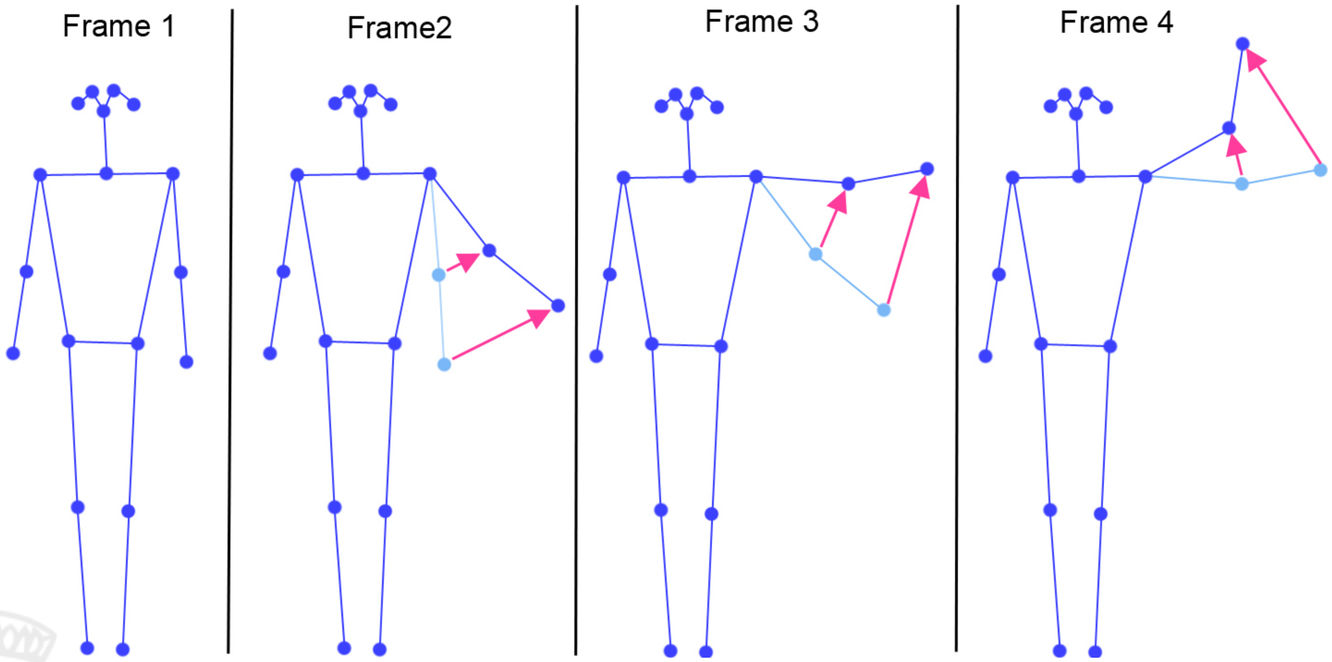

Differenza tra la posa al frame *f* e quella al frame *f+1*

$$\mathcal{T}_f = \mathcal{P}_{f+1} - \mathcal{P}_f$$

$$= \bigcup_{k \in K} p_{k,f+1} - p_{k,f}$$

Metodo proposto - **Tecniche di rielaborazione**

UNIVERSITÀ DEGLI STUDI FIRENZE

Semplice | Baricentro | **Next frame**

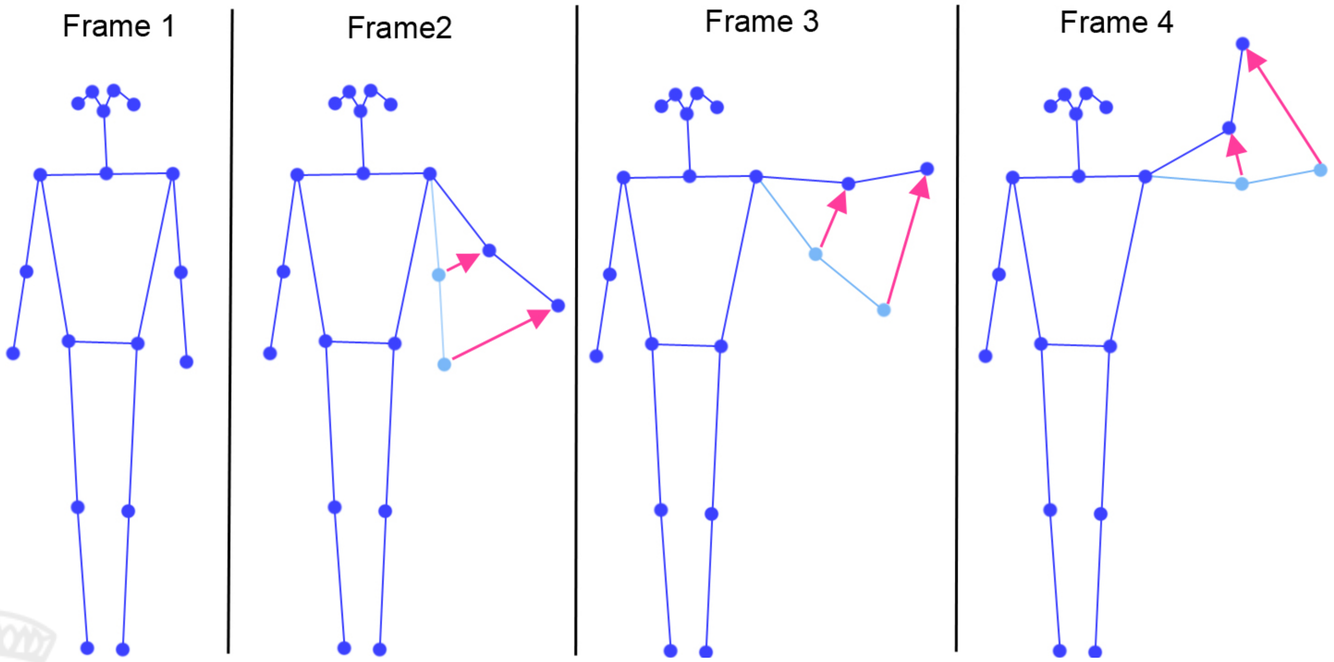

Differenza tra la posa al frame *f* e quella al frame *f*+***S***

$$\mathcal{T}_f = \mathcal{P}_{f+S} - \mathcal{P}_f$$

$$= \bigcup_{k \in K} p_{k,f+S} - p_{k,f}$$

$$\boldsymbol{S} = \{1, 3, 7, 15\}$$

Metodo proposto - **Tecniche di rielaborazione**

UNIVERSITÀ DEGLI STUDI FIRENZE

Semplice | Baricentro | Next frame | **Distanze cumulate**

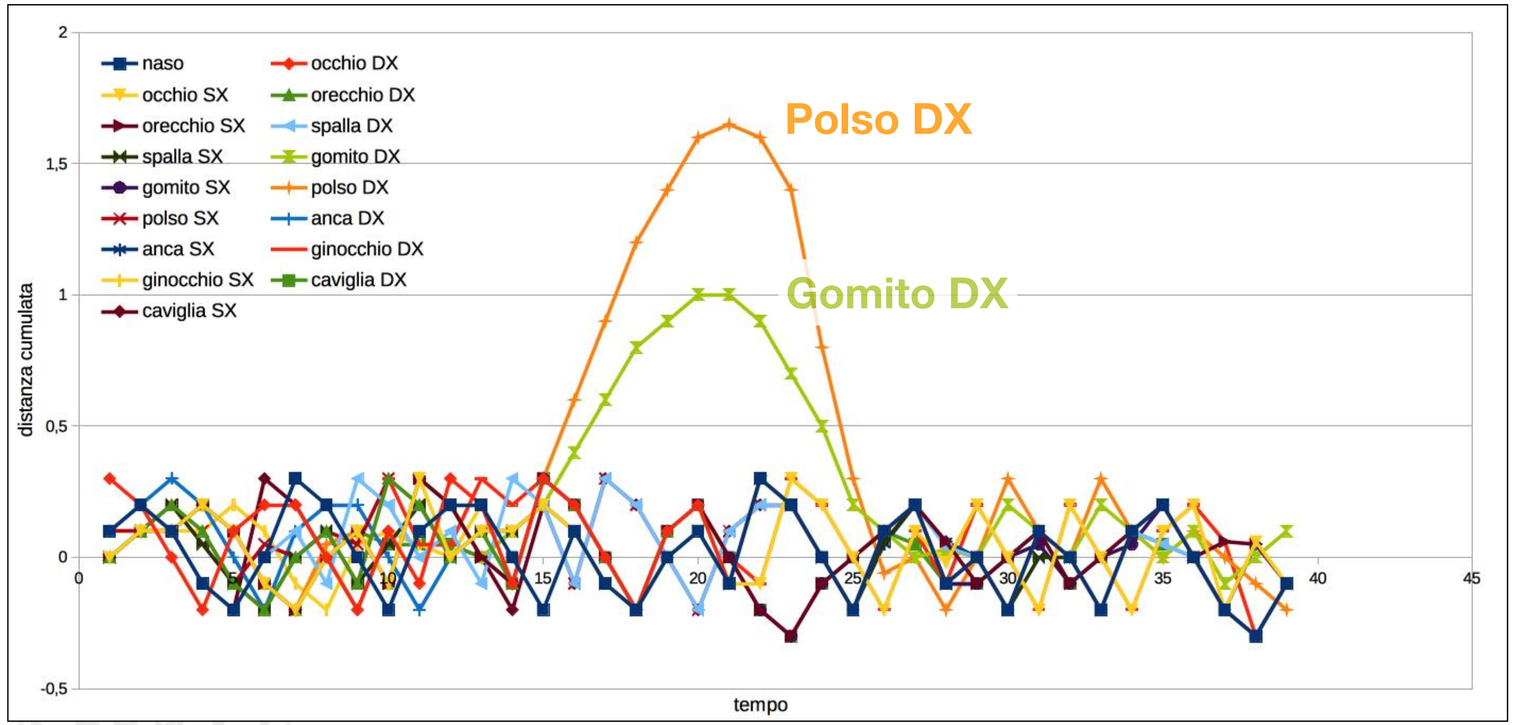

Evoluzione della posa per l'azione "Alzare e abbassare il braccio destro"

Somma delle differenze di posa fino al frame *f*

$$\mathcal{T}_f = \sum_{j=1}^{f-1} \mathcal{P}_{j+1} - \mathcal{P}_j$$

$$= \bigcup_{k \in K} \sum_{j=1}^{f-1} p_{k,j+1} - p_{k,j}$$

Metodo proposto - **Tecniche di rielaborazione**

UNIVERSITÀ DEGLI STUDI FIRENZE

Semplice | Baricentro | Next frame | Distanze cumulate | **Distanze relative**

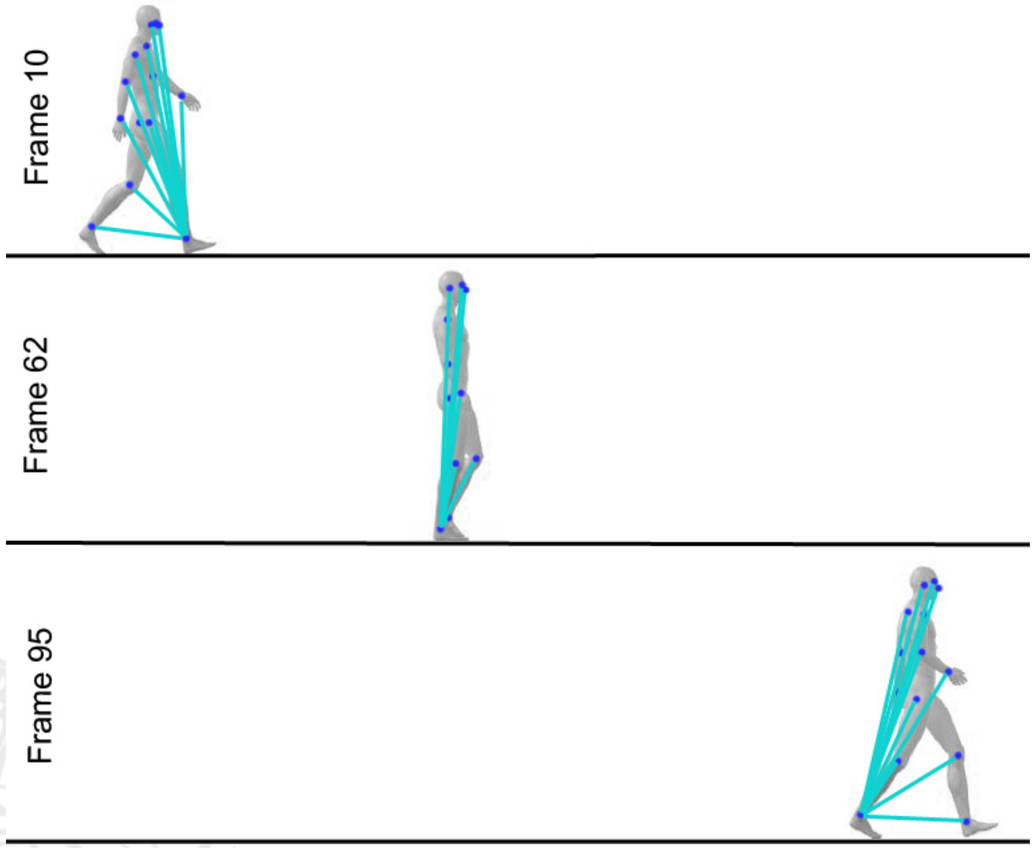

Distanza **euclidea** fra ogni giunto e **tutti gli altri** della stessa posa.

$$\mathcal{P}_f \in \mathbb{R}^{K\times 2} \quad \longrightarrow \quad \mathcal{T}_f \in \mathbb{R}^{K\times K}$$

$$\mathcal{T}_f = \bigcup_{i\in K}\bigcup_{j\in K} t_{ij}$$

$$= \bigcup_{i\in K}\bigcup_{j\in K} \mathrm{eucl}(p_{if}, p_{jf})$$

Fase 1 - **Esplorazione tecniche**

UNIVERSITÀ DEGLI STUDI FIRENZE

Tecniche di rielaborazione totali: **20** Detectron2 + **20** PoseNet

Database: **8 azioni**

- 3 coppie di azioni simili
- 1 azione di coppia

Data augmentation: Mirroring + Jittering

Ottimizzatore: RMSProp

Loss function: Categorical Cross Entropy

$$f(s)_i = \frac{e^{s_i}}{\sum_j^C e^{s_j}} \qquad CCE = -\sum_i^C t_i \cdot \log\left(f(s)_i\right)$$

Struttura Rete: **1 livello LSTM**

64 hidden units

Batch size: 80

Epoche: **100**

LR: Graduale discendente 10^{-2} → 10^{-3}

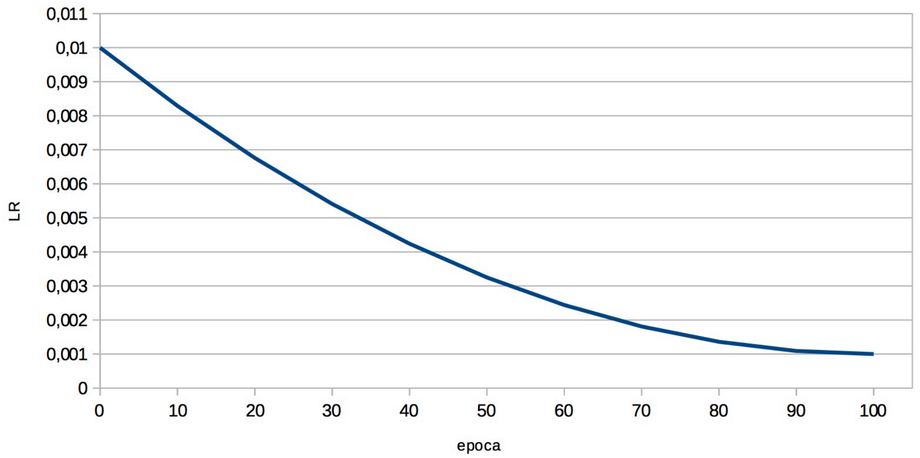

2 Checkpoint: - Max accuratezza di validazione
- Min loss di validazione

Fase 1 - **Esplorazione tecniche**

UNIVERSITÀ DEGLI STUDI FIRENZE

Tecniche di rielaborazione totali: **20** Detectron2 + **20** PoseNet

Database: **8 azioni**

- 3 coppie di azioni simili
- 1 azione di coppia

Data augmentation: Mirroring + Jittering

Ottimizzatore: RMSProp

Loss function: Categorical Cross Entropy

$$f(s)_i = \frac{e^{s_i}}{\sum_j^C e^{s_j}} \qquad CCE = -\sum_i^C t_i \cdot \log\left(f(s)_i\right)$$

Struttura Rete: **1 livello LSTM**

64 hidden units

Batch size: 80

TECNICA	1 Livello LSTM					
	DETECTRON			POSENET		
	Media	CV	CS	Media	CV	CS
rimoz 0 + VIDEO + norm	63,53	66,14	60,92	53,88	59,22	48,55
rimoz 0 + FRAME + norm	63,29	65,98	60,60	57,96	59,89	56,02
rimoz 0 + FRAME PERS + norm	62,48	64,04	60,92	58,11	58,78	57,43
rimoz 0 + FRAME + norm (MIN LOSS)	62,17	65,23	59,10	57,18	59,02	55,34
rimoz 0 + NEXT 3 + norm	61,00	62,22	59,78	59,63	62,74	56,52
rimoz 0 + FRAME PERS + norm (MIN LOSS)	60,92	63,05	58,79	55,63	56,69	54,57
rimoz 0 + DIST REL + norm	60,22	64,56	55,89	51,28	48,89	53,67
rimoz 0 + 3BAR + norm	60,17	66,81	53,53	57,39	53,40	61,37
rimoz 0 + 3BAR ASS + norm (MIN LOSS)	59,60	63,85	55,34	62,03	62,46	61,59
rimoz 0 + 3BAR ASS + norm	59,47	64,64	54,30	63,04	61,67	64,40
rimoz 0 + VIDEO + norm (MIN LOSS)	59,31	61,27	57,34	52,53	59,22	45,83
rimoz 0 + 5BAR + norm	59,06	56,29	61,82	60,59	62,34	58,83
rimoz 0 + DIST CUM + norm	58,64	61,75	55,53	32,93	12,50	53,35
rimoz 0 + DIST REL + norm (MIN LOSS)	58,46	61,71	55,21	51,61	49,64	53,58
rimoz 0 + VIDEO PERS + norm (MIN LOSS)	58,12	59,14	57,11	57,87	60,52	55,21
rimoz 0 + 3BAR + norm (MIN LOSS)	57,60	64,44	50,77	55,76	49,96	61,55
rimoz 0 + 17BAR ASS + norm	57,03	62,30	51,77	54,71	58,19	51,22
rimoz 0 + 5BAR + norm (MIN LOSS)	55,41	53,13	57,70	54,83	55,58	54,08
normXY	55,04	60,13	49,96	57,15	55,10	59,19
normXY (MIN LOSS)	54,69	59,65	49,73	52,89	54,55	51,22
norm	53,96	55,66	52,26	53,88	55,46	52,31
norm (MIN LOSS)	53,76	55,62	51,90	53,46	55,10	51,81
rimoz 0 + norm (MIN LOSS)	53,56	53,44	53,67	52,64	53,24	52,04
rimoz 0 + VIDEO PERS + norm	52,65	57,12	48,19	14,99	12,54	17,44
rimoz 0 + DIST CUM + norm (MIN LOSS)	52,41	59,26	45,56	30,16	12,54	47,78
rimoz 0 + norm	52,29	54,98	49,59	51,98	53,24	50,73
rimoz 0 + 5BAR ASS + norm	51,17	47,23	55,12	53,42	53,80	53,03
rimoz 0 + 17BAR ASS + norm (MIN LOSS)	49,93	55,34	44,52	50,52	56,21	44,84
rimoz 0 + 5BAR ASS + norm (MIN LOSS)	48,80	46,56	51,04	47,78	45,69	49,86
rimoz 0 + NEXT 3 + norm (MIN LOSS)	47,16	46,72	47,60	12,57	12,54	12,59
Semplice	39,49	43,47	35,51	42,09	43,51	40,67
Semplice (MIN LOSS)	39,38	43,16	35,60	42,21	42,88	41,53
rimoz 0 + 17BAR + norm	34,96	12,54	57,38	33,18	12,50	53,85
rimoz 0 + 17BAR + norm (MIN LOSS)	33,99	12,54	55,44	32,86	12,54	53,17
rimoz 0 + NEXT 7 + norm	12,54	12,58	12,50	29,50	13,85	45,15
rimoz 0 + NEXT 15 + norm	12,52	12,54	12,50	21,40	30,30	12,50
rimoz 0 + NEXT 15 + norm (MIN LOSS)	12,52	12,54	12,50	21,48	30,46	12,50
rimoz 0 + NEXT 7 + norm (MIN LOSS)	12,52	12,54	12,50	25,40	13,85	36,96
rimoz 0 + NEXT + norm (MIN LOSS)	12,52	12,54	12,50	12,52	12,50	12,55
rimoz 0 + NEXT + norm	12,47	12,54	12,41	12,54	12,54	12,55

Fase 2 - **Esplorazione livelli**

UNIVERSITÀ DEGLI STUDI FIRENZE

Tecniche di rielaborazione totali: **9** Detectron2 + **9** PoseNet

Database: 8 azioni
- 3 coppie di azioni simili
- 1 azione di coppia

Data augmentation: Mirroring + Jittering

Struttura Rete: **1-2-3 livelli LSTM**
64 hidden units

Batch size: 80

TECNICA	1 Livello LSTM						2 Livelli LSTM						3 Livelli LSTM					
	DETECTRON			POSENET			DETECTRON			POSENET			DETECTRON			POSENET		
	Media	CV	CS	Media	CV	CS	Media	CV	CS	Media	CV	CS	Media	CV	CS	Media	CV	CS
rimoz 0 + VIDEO + norm	**63,53**	*66,14*	*60,92*	53,88	*59,22*	*48,55*	60,43	*61,71*	*59,15*	**57,00**	*57,83*	*56,16*	59,24	*62,82*	*55,66*	56,86	*60,09*	*53,62*
rimoz 0 + FRAME + norm	63,29	*65,98*	*60,60*	**57,96**	*59,89*	*56,02*	**63,43**	*64,72*	*62,14*	56,91	*58,03*	*55,80*	33,02	*12,50*	*53,53*	12,50	*12,50*	*12,50*
rimoz 0 + FRAME PERS + norm	**62,48**	*64,04*	*60,92*	**58,11**	*58,78*	*57,43*	57,52	*59,65*	*55,39*	57,88	*59,65*	*56,11*	36,16	*59,81*	*12,50*	55,30	*56,80*	*53,80*
rimoz 0 + FRAME + norm (MIN LOSS)	**62,17**	*65,23*	*59,10*	**57,18**	*59,02*	*55,34*	61,28	*62,10*	*60,46*	55,28	*57,20*	*53,35*	32,77	*12,50*	*53,03*	12,50	*12,50*	*12,50*
rimoz 0 + NEXT 3 + norm	61,00	*62,22*	*59,78*	**59,63**	*62,74*	*56,52*	60,83	*64,91*	*56,75*	58,52	*58,35*	*58,70*	**61,14**	*61,91*	*60,37*	32,81	*12,50*	*53,13*
rimoz 0 + FRAME PERS + norm (MIN LOSS)	**60,92**	*63,05*	*58,79*	55,63	*56,69*	*54,57*	56,71	*59,61*	*53,80*	**56,76**	*56,05*	*57,47*	33,90	*55,30*	*12,50*	54,77	*56,69*	*52,85*
rimoz 0 + DIST REL + norm	**60,22**	*64,56*	*55,89*	51,28	*48,89*	*53,67*	59,88	*59,97*	*59,78*	55,96	*57,16*	*54,76*	59,00	*62,66*	*55,34*	**58,64**	*62,66*	*54,62*
rimoz 0 + 3BAR + norm	60,17	*66,81*	*53,53*	57,39	*53,40*	*61,37*	**62,63**	*61,71*	*63,54*	**60,35**	*62,74*	*57,97*	59,44	*61,27*	*57,61*	58,64	*58,03*	*59,24*
rimoz 0 + 3BAR ASS + norm (MIN LOSS)	59,60	*63,85*	*55,34*	**62,03**	*62,46*	*61,59*	59,11	*62,07*	*56,16*	61,70	*61,99*	*61,41*	**61,63**	*60,72*	*62,55*	59,18	*60,84*	*57,52*
rimoz 0 + 3BAR ASS + norm	59,47	*64,64*	*54,30*	**63,04**	*61,67*	*64,40*	61,86	*59,42*	*64,31*	60,89	*61,59*	*60,19*	**62,22**	*61,35*	*63,09*	61,22	*60,52*	*61,91*
rimoz 0 + VIDEO + norm (MIN LOSS)	59,31	*61,27*	*57,34*	52,53	*59,22*	*45,83*	**59,49**	*60,64*	*58,33*	**55,54**	*55,38*	*55,71*	59,32	*60,52*	*58,11*	55,04	*57,99*	*52,08*
rimoz 0 + 5BAR + norm	59,06	*56,29*	*61,82*	**60,59**	*62,34*	*58,83*	**63,92**	*63,87*	*58,97*	57,86	*56,21*	*59,51*	34,85	*12,58*	*57,11*	33,13	*53,76*	*12,50*
rimoz 0 + DIST CUM + norm	**58,64**	*61,75*	*55,53*	32,93	*12,50*	*53,35*	56,70	*58,82*	*54,57*	**56,33**	*57,67*	*54,98*	36,00	*59,49*	*12,50*	54,45	*54,91*	*53,99*
rimoz 0 + DIST REL + norm (MIN LOSS)	58,46	*61,71*	*55,21*	51,61	*49,64*	*53,58*	**59,84**	*59,53*	*60,15*	56,25	*57,16*	*55,34*	57,34	*59,06*	*55,62*	**57,60**	*60,80*	*54,39*
rimoz 0 + VIDEO PERS + norm (MIN LOSS)	58,12	*59,14*	*57,11*	57,87	*60,52*	*55,21*	60,83	*64,91*	*56,75*	**58,52**	*58,35*	*58,70*	**61,14**	*61,91*	*60,37*	32,81	*12,50*	*53,13*
rimoz 0 + 3BAR + norm (MIN LOSS)	57,60	*64,44*	*50,77*	55,76	*49,96*	*61,55*	**60,10**	*60,32*	*59,87*	**58,37**	*62,03*	*54,71*	56,30	*56,88*	*55,71*	58,06	*58,47*	*57,65*

Fase 3 - **Dropout e Regolarizzatore**

UNIVERSITÀ DEGLI STUDI FIRENZE

Tecniche di rielaborazione totali: **9** Detectron2 + **9** PoseNet

Database: **60 azioni**

Data augmentation: Mirroring + Jittering

Epoche: 100 *LR*: 10^{-3}

Struttura Rete: 2-3 livelli LSTM
64 hidden units

Batch size: 600

Dropout: **5% - 50%**

Regolarizzatore: **10^{-1} - 10^{-8}**

Detectron2

Media	*Cross view*	*Cross Subject*	*Nome*	*Drop (%)*	*Reg*	*Liv LSTM*
84,30	88,89	79,71	**3 BAR**	15	10^{-5}	3
84,23	88,66	79,81	**3 BAR**	15		3
83,86	87,64	80,08	**NEXT 3**	15	10^{-5}	3
83,76	88,54	78,98	3 BAR (ML)	15		3
83,56	88,04	79,08	NEXT 3	10		3
⋮	⋮	⋮	⋮	⋮	⋮	⋮

PoseNet

Media	*Cross view*	*Cross Subject*	*Nome*	*Drop (%)*	*Reg*	*Liv LSTM*
76,05	80,09	72,00	**3 BAR**	15		3
75,99	79,82	72,15	**NEXT 3**	15	10^{-6}	3
75,84	78,91	72,77	**3 BAR** (ML)	10	10^{-6}	3
75,83	78,69	72,97	NEXT 3	10	10^{-6}	3
75,81	79,95	71,68	5 BAR	5	10^{-6}	3
⋮	⋮	⋮	⋮	⋮	⋮	⋮

Fase 4 - **Addestramento completo**

UNIVERSITÀ DEGLI STUDI FIRENZE

Tecniche di rielaborazione totali: **6** Detectron2 + **6** PoseNet

Database: 60 azioni
Data augmentation: Mirroring + Jittering

Epoche: ∞ *LR*: 10^{-3}

Struttura Rete: 2-3 livelli LSTM
64 hidden units
Batch size: 600
Dropout: 5% - 50%
Regolarizzatore: 10^{-1} - 10^{-8}

Detectron2

Media	*Cross view*	*Cross Subject*	*Nome*	*Drop (%)*	*Reg*	*Liv LSTM*
86,84	91,89	81,78	3 BAR GLOB XY	15	10^{-5}	3
86,62	91,72	81,52	3 BAR GLOB	15	10^{-5}	3
86,10	90,72	81,47	NEXT 3 XY	15	10^{-5}	3
85,70	89,80	81,59	3 BAR	15		3
85,35	89,22	80,74	NEXT 3	15	10^{-5}	3
85,18	89,02	81,33	3 BAR XY	15		3

PoseNet

Media	*Cross view*	*Cross Subject*	*Nome*	*Drop (%)*	*Reg*	*Liv LSTM*
82,51	87,47	77,55	3 BAR XY	10		3
82,15	86,98	77,32	3BAR	10		3
81,55	85,60	77,50	3 BAR GLOB	15		3
80,01	84,64	75,38	3 BAR GLOB XY	15		3
78,90	82,74	75,06	NEXT 3 XY	15	10^{-5}	3
77,64	81,74	73,53	NEXT 3	15	10^{-5}	3

Fase 5 - **Combinazione**

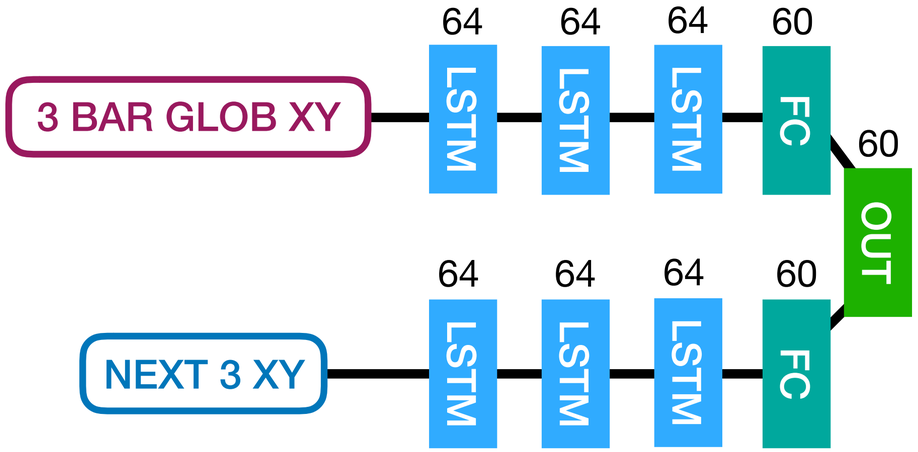

Detectron2

Media	*Cross view*	*Cross Subject*	*Nome*	*Drop (%)*	*Reg*	*Liv LSTM*
88,51 (+1.67)	**93,69**	**83,32**	**3 BAR** GLOB XY + **NEXT 3** XY	**15** **15**	**10^{-5}** **10^{-5}**	**3** **3**
85,05	90,23	79,87	3 BAR GLOB XY + 3 BAR XY	15 15	10^{-5}	3 3

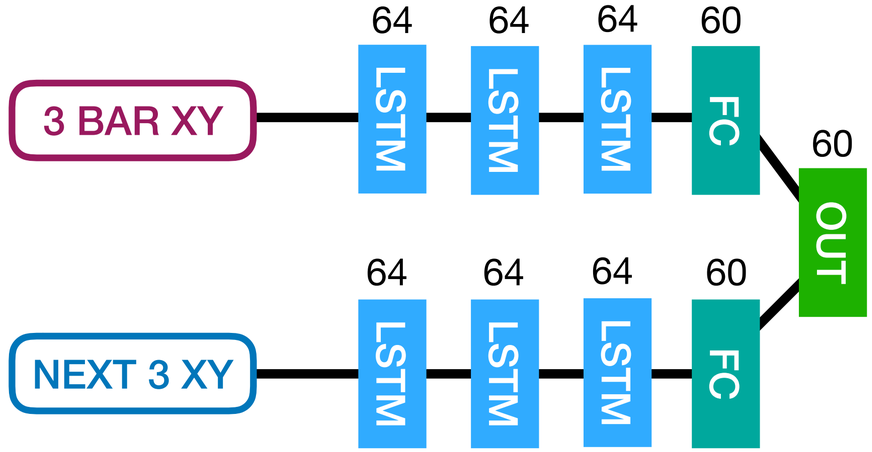

PoseNet

Media	*Cross view*	*Cross Subject*	*Nome*	*Drop (%)*	*Reg*	*Liv LSTM*
83,43 (+0,92)	**87,79**	**79,06**	**3 BAR** XY + **NEXT 3** XY	**10** **15**	**10^{-5}**	**3** **3**
81,56	85,39	77,74	3 BAR GLOB XY + NEXT 3 XY	15 15	10^{-5} 10^{-5}	3 3

Loss function:

$$\mathcal{L} = \alpha \cdot \mathcal{L}_1 + \alpha \cdot \mathcal{L}_2$$

$\mathcal{L}_1$ = loss function prima tecnica

$\mathcal{L}_2$ = loss function seconda tecnica

α = 0.5

Conclusioni

UNIVERSITÀ DEGLI STUDI FIRENZE

Articolo	Posa	RGB	IR	Cross View (%)	Cross subject (%)	Media
Action machine		X		97,2	94,3	95,75
Glimpse Clouds		X		93,2	86,6	89,90
2D-3D-Softargmax		X		-	85,5	-
3BAR-NEXT-Detectron		X		**93,69**	**83,32**	**88,51**
Chained		X		-	80,8	-
3BAR-NEXT-PoseNet		X		**87,79**	**79,06**	**83,43**
DSSCA-SSLM		X		-	74,9	-
MMTM	X	X		-	91,99	-
PoseMap	X	X		95,2	91,7	93,45
FUSION	X		X	94,5	91,6	93,05
MFAS	X	X		-	90,04	-
PB-GCN	X			93,2	87,5	90,35
SR-TSL	X			92,4	84,8	88,60
ST-GCN	X			88,3	81,5	84,90
VA-LSTM	X			87,6	79,4	83,5
C-CNN-MTLN	X			84,8	79,6	82,2
Skelemotion	X			84,7	76,5	80,6
Temporal Conv	X			83,1	74,3	78,78
ST-LSTM+TS	X			77,7	69,2	73,45
Deep LSTM	X			70,3	62,9	66,60
PA-LSTM	X			67,3	60,7	64,00
H-RNN	X			64,0	59,1	61,55
Lie Group	X			52,8	50,1	51,45

Test sul campo

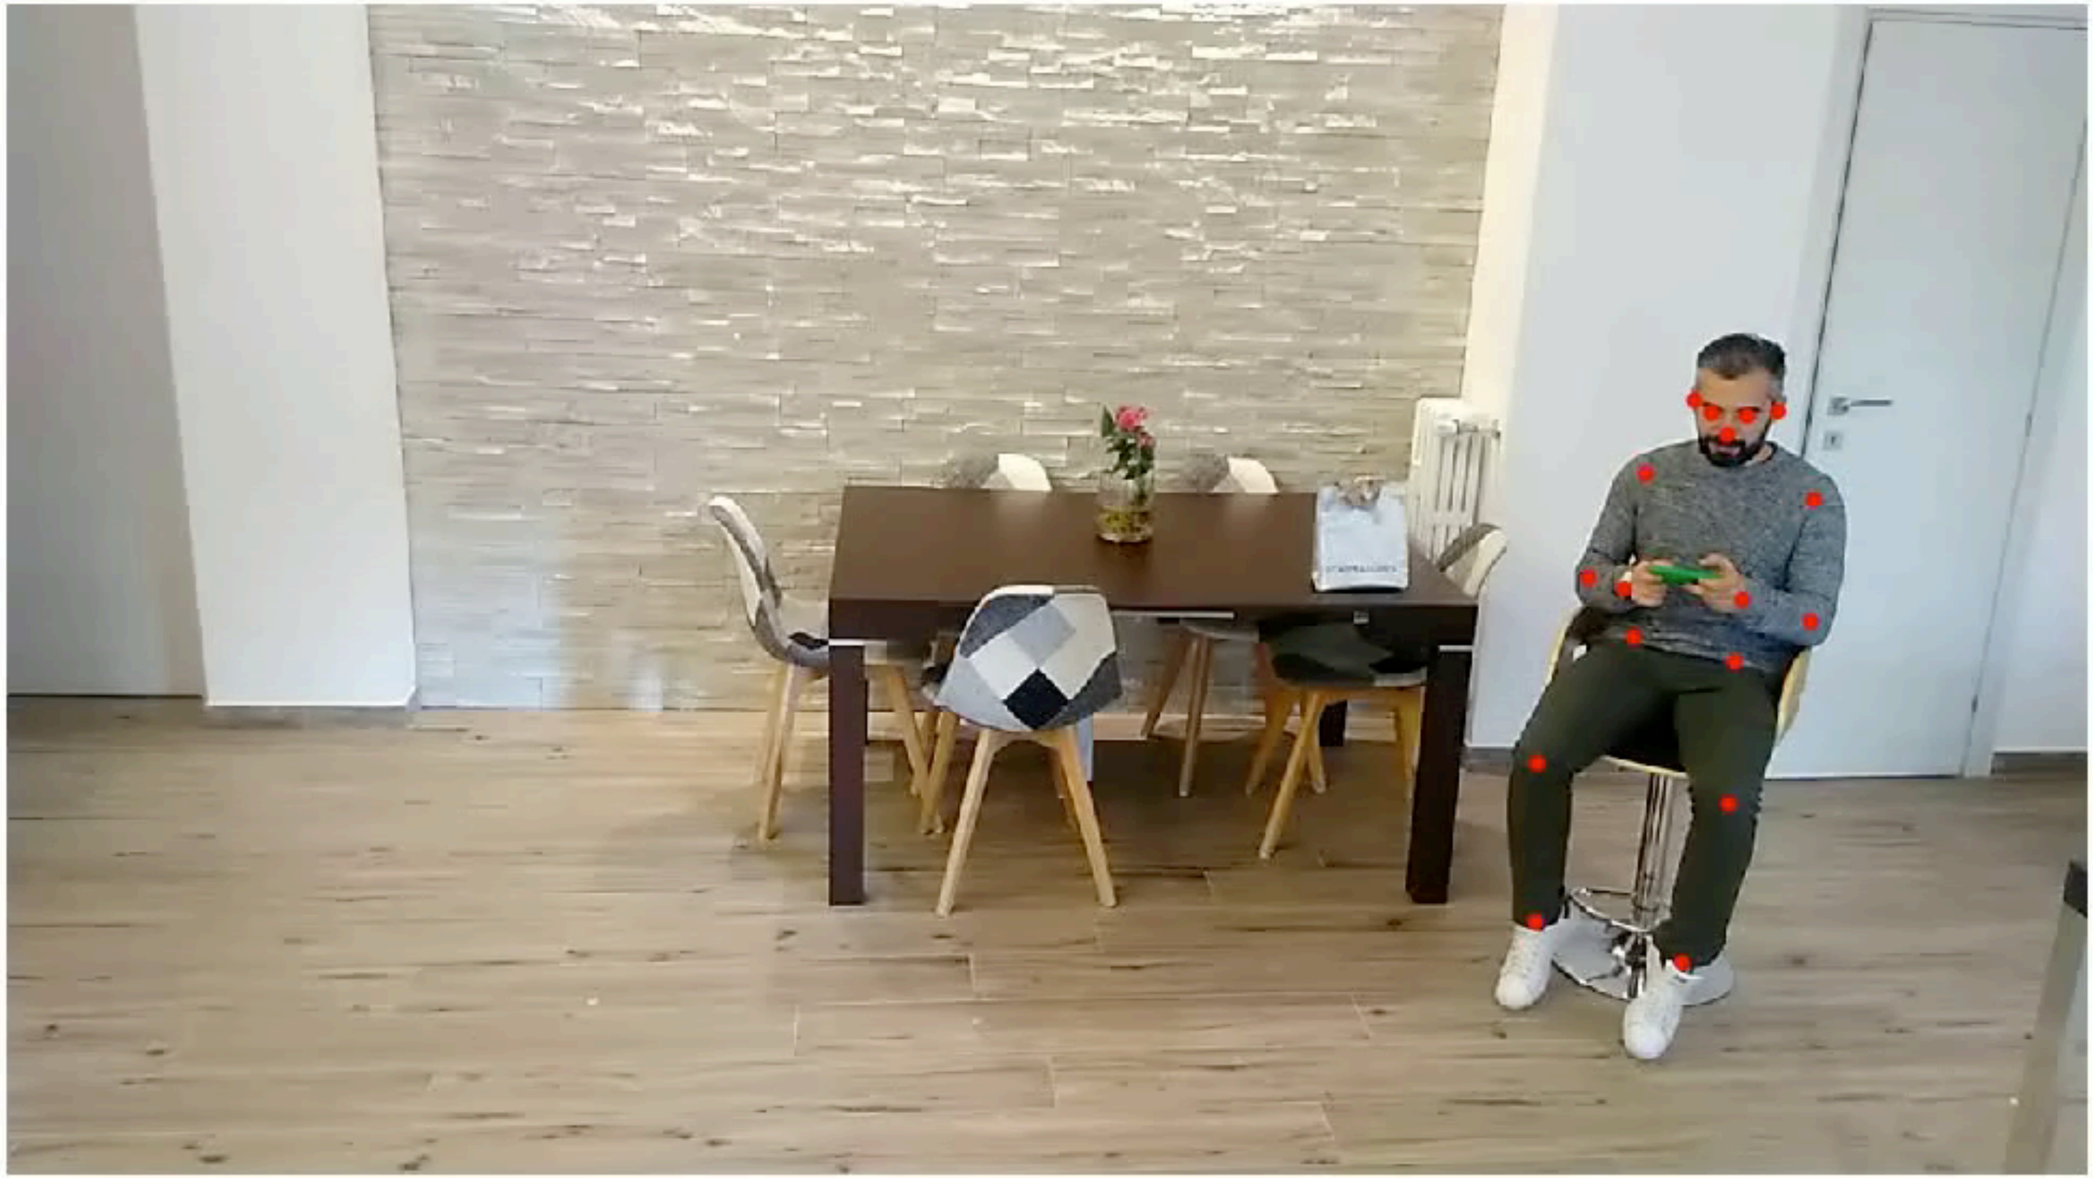

Sviluppi futuri

- Utilizzare le informazioni provenienti anche da una classificazione ottenuta direttamente dai dati RGB

- Testare funzioni loss combinate diverse fra le migliori tecniche (massimo score, α diverso da 0.5, …)

- Testare l'algoritmo anche sui dataset *NTU-RGB+D120*, *MSR Daily Activity3D* e *Northwestern-UCLA Multiview Action 3D* (NUCLA)

Grazie!

Spare slides

1 - drink water
2 - eat meal/snack
3 - brushing teeth
4 - brushing hair
5 - drop
6 - pickup
7 - throw
8 - sitting down
9 - standing up (from sitting position)
10 - clapping
11 - reading
12 - writing
13 - tear up paper
14 - wear jacket
15 - take off jacket
16 - wear a shoe
17 - take off a shoe
18 - wear on glasses
19 - take off glasses
20 - put on a hat/cap
21 - take off a hat/cap
22 - cheer up
23 - hand waving
24 - kicking something
25 - reach into pocket
26 - hopping (one foot jumping)
27 - jump up
28 - make a phone call/answer phone
29 - playing with phone/tablet
30 - typing on a keyboard
31 - pointing to something with finger
32 - taking a selfie
33 - check time (from watch)
34 - rub two hands together
35 - nod head/bow
36 - shake head
37 - wipe face
38 - salute
39 - put the palms together
40 - cross hands in front (say stop)
41 - sneeze/cough
42 - staggering
43 - falling
44 - touch head (headache)
45 - touch chest (stomachache/heart pain)
46 - touch back (backache)
47 - touch neck (neckache)
48 - nausea or vomiting condition
49 - use a fan (with hand or paper)/feeling warm
50 - punching/slapping other person
51 - kicking other person
52 - pushing other person
53 - pat on back of other person
54 - point finger at the other person
55 - hugging other person
56 - giving something to other person
57 - touch other person's pocket
58 - handshaking
59 - walking towards each other
60 - walking apart from each other.

Metodo proposto - **Tecniche di rielaborazione**

Normalizzazione

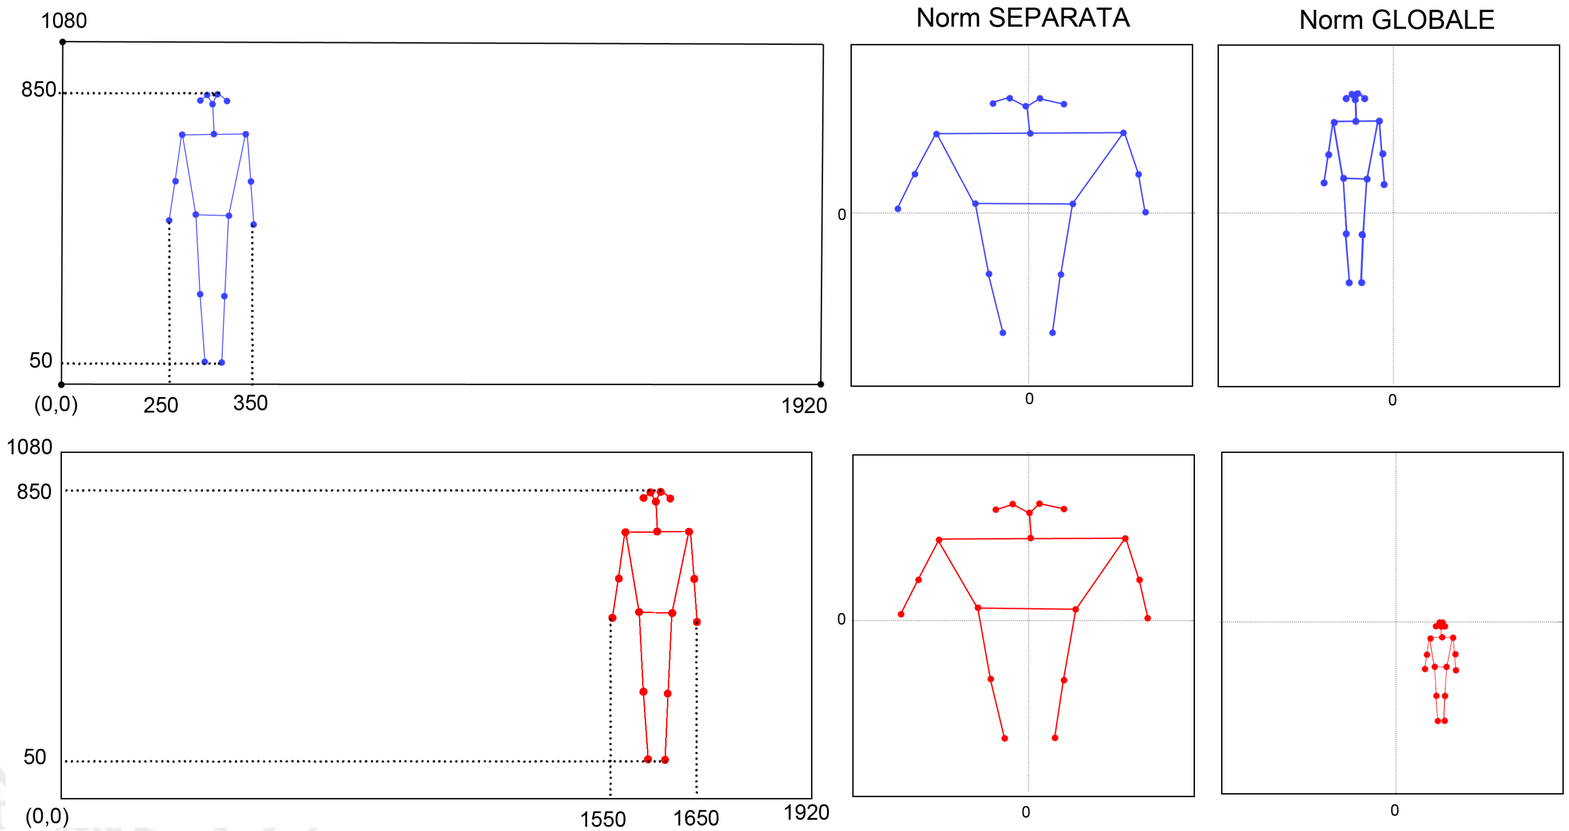

Normalizzazione **Separata:**
le dimensioni in input vengono normalizzate separatamente. Particolarmente adatta quando l'input rappresenta **punti nel piano o vogliamo separare l'importanza delle dimensioni**

Normalizzazione **Globale:**
le dimensioni in input vengono normalizzate globalmente